HUST

TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

ONE LOVE. ONE FUTURE.



TRƯỜNG ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

Calibrated Reliability-Informed Structured Pseudo-labeling for Domain Adaptation (CRISP – DA)

- New proposal ideas -

Student name/Student ID: *Phan Dinh Trung/20230093*

Supervisor: Dr. Nguyen Thi Oanh

Course: *Project III*

ONE LOVE. ONE FUTURE.

Introduction

Motivations

1. Confidence-only self-training là chưa đủ

- Trong UDASS, **confidence cao không đồng nghĩa pseudo-label đúng**; Teacher vẫn có thể dự đoán sai nhưng rất tự tin.
- Một **global confidence threshold** dễ gây lỗi:
  - giữ lại pseudo-label sai nhưng confidence cao;
  - loại bỏ các pixel khó nhưng vẫn hữu ích, đặc biệt ở vùng boundary.
- **Propose:** Reliability score của dự đoán cần được đánh giá từ nhiều evidence, không chỉ từ confidence:
  - **Predictive confidence** của Teacher model.
  - **Augmentation consistency** kiểm tra prediction có bền vững trước nhiễu hay không.
  - **Distribution compatibility** kiểm tra target feature có phù hợp với class-conditional semantic distribution hay không.
  - **Temporal stability** kiểm tra prediction có ổn định qua training không.
  - **Boundary evidence** mô tả mức độ khó về không gian.

- Mục tiêu không phải chứng minh các evidence hoàn toàn độc lập thống kê, mà là cung cấp các góc nhìn bổ sung để giảm phụ thuộc vào một scalar confidence duy nhất.

Motivation

2. Hạn chế của một số phương pháp về trạng thái của Pseudolabel ở từng vòng training

- Uncertainty trong segmentation không đồng nhất, và có nhiều dạng khác nhau:
  - Có pixel đủ đáng tin để giữ nguyên.
  - Có pixel mà Teacher đáng nghi nhưng prototype distribution hỗ trợ rõ một class khác.
  - Có pixel chưa đủ chắc để hard-assign nhưng phân phối xác suất vẫn giàu thông tin.
  - Có pixel quá mơ hồ nên tốt nhất tạm thời không học.

Motivation

3. Một semantic class trong feature space thường không tạo thành một cụm đơn giản quanh một centroid duy nhất

- **Một class có tính đa dạng nội tại rất lớn.** Ví dụ class car có thể xuất hiện ở nhiều scale, góc nhìn, khoảng cách, mức che khuất và điều kiện ánh sáng khác nhau. Nếu chỉ dùng một prototype toàn bộ class bị ép thành một phân phối gần như unimodal, nên representation thường quá thô.

- **Một centroid không mô tả được độ phân tán của class.** Hai feature có thể cách prototype một khoảng tương tự nhưng thuộc các vùng có mức uncertainty khác nhau. Vì vậy CRISP-DA lưu them các thông tin như độ phân tán, centroid, tỉ lệ weight của mode trong class

- **Cần một semantic reference độc lập với softmax confidence.** Teacher có thể dự đoán một pseudo-label với confidence cao nhưng feature lại không phù hợp với distribution của class đó. Bank cho phép kiểm tra và sinh **distribution compatibility** giúp phát hiện các trường hợp confidently wrong.

4. Cơ chế cập nhật Threshold dynamic

Pseudo-label quality và learning speed khác nhau rõ giữa các class. Nếu mọi class dung cùng một threshold, các class dễ, chiếm diện tích lớn như *road*, *building*, *sky* thường đạt confidence cao sớm và tạo phần lớn supervision. Các class nhỏ hoặc khó như rider, pole, traffic sign có ít pseudo-label hơn, vì thế cải thiện chậm hơn và càng khó vượt threshold trong các epoch sau.

Contributions

- **Multi-evidence reliability calibration** ở mức pixel, trong đó *reliability score* được ước lượng từ nhiều thông tin khác nhau thay vì lấy trực tiếp từ *max-softmax*.

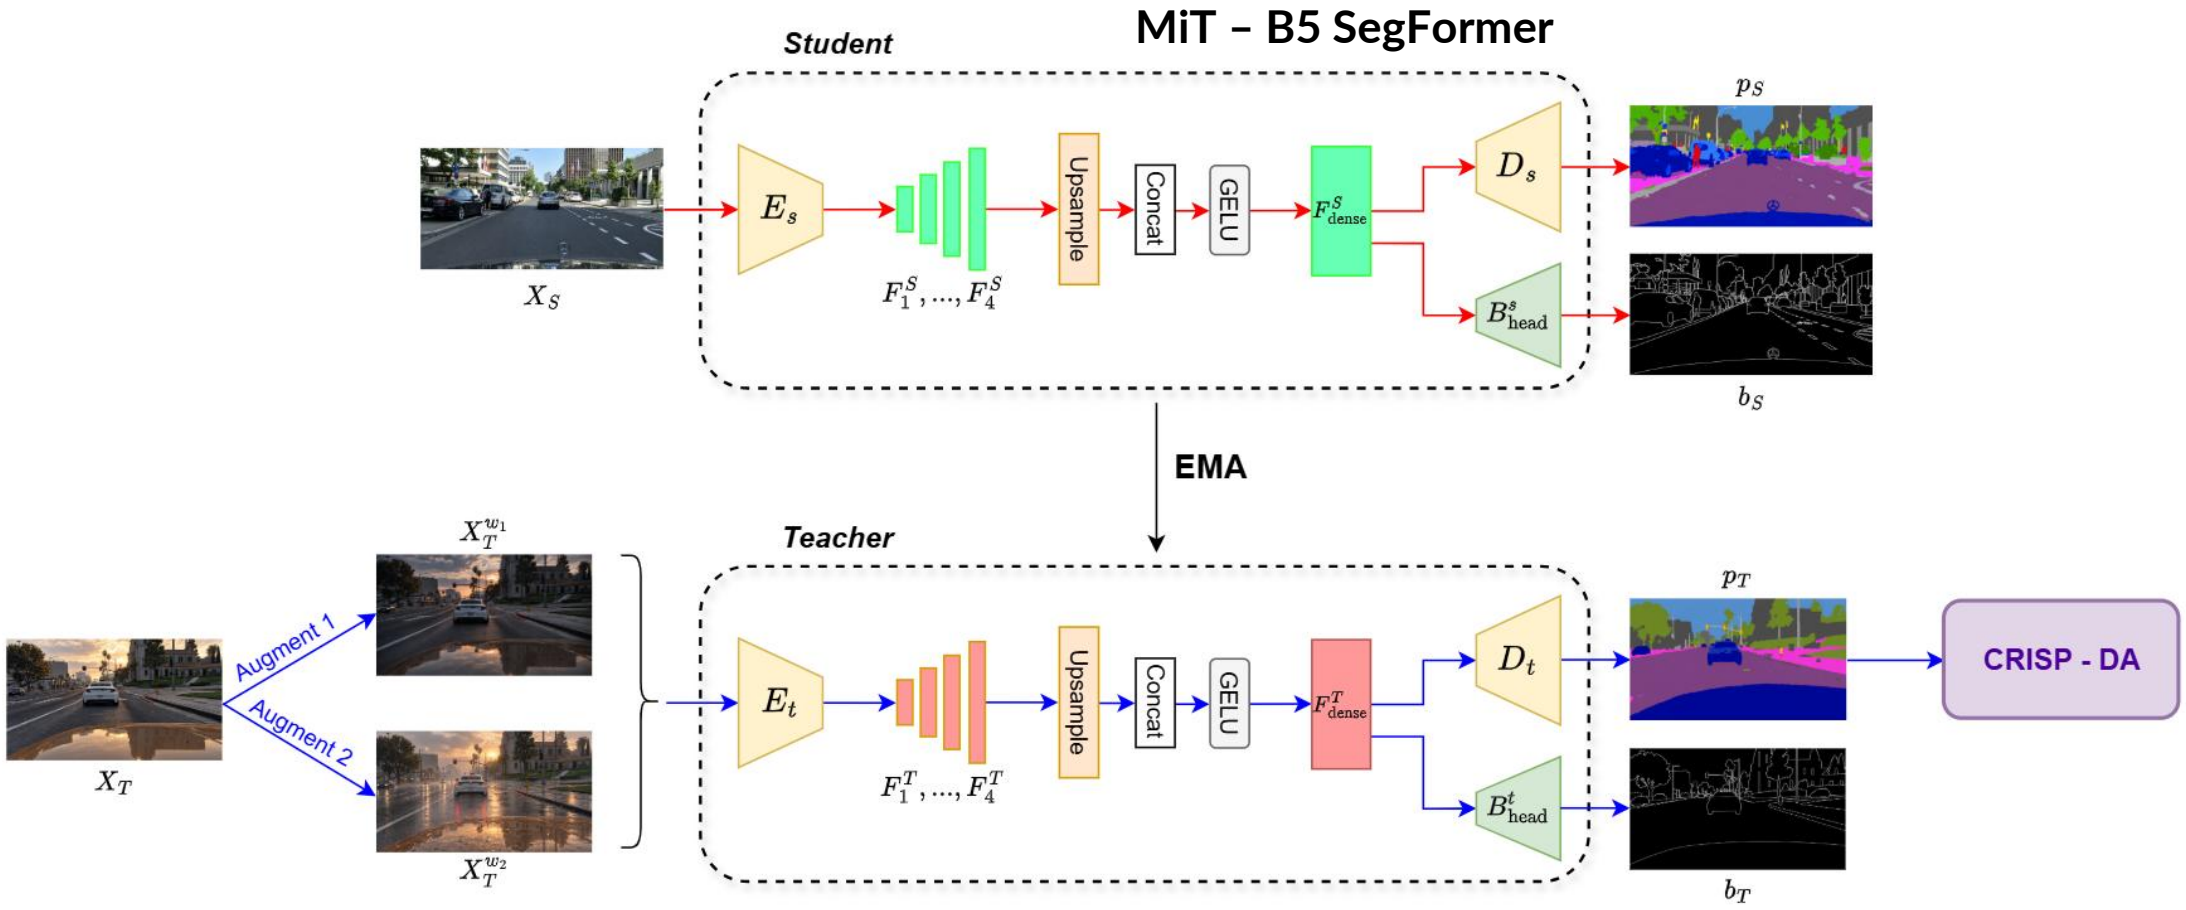
- **Four-state supervision routing**, biến reliability thành bốn cách sử dụng pseudo-label khác nhau thay vì Keep/Ignore: **ACCEPT** - giữ Teacher hard label ; **REVISE** - sửa hard pseudo-label bằng alternative evidence ; **SOFT SUPERVISE** - giữ uncertainty thay vì ép integer class ; **ABSTAIN**: không dùng pseudo-supervision tại iteration hiện tại.

- **Reliability-gated class-conditional distribution adaptation**: Cơ chế **Multi-prototype bank** được bootstrap từ source và chỉ nhận target features sau khi vượt qua policy tin cậy, nhằm cân bằng giữa target adaptation và contamination control.

- **Balanced progressive coverage**, cho phép threshold thay đổi theo class và theo thời gian training. Curriculum này trực tiếp điều khiển Four-State Policy thay vì chỉ quyết định một confidence threshold toàn cục.

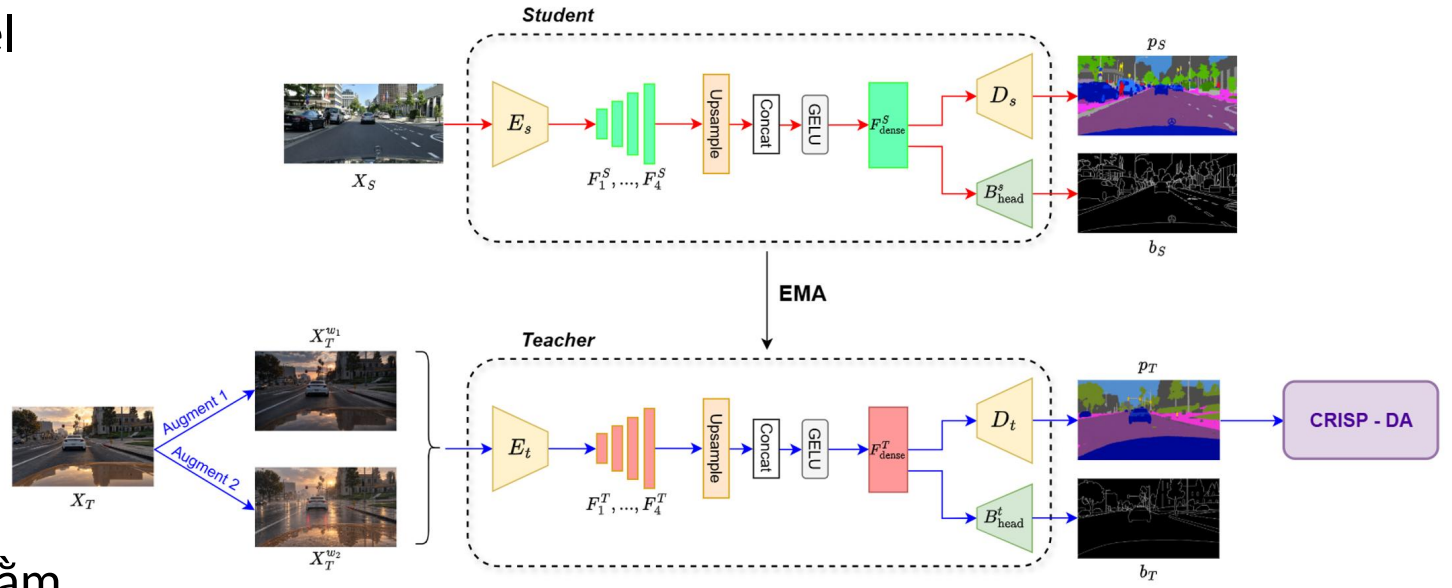
Methodology

Tổng quan kiến trúc



Tổng quan kiến trúc

- **Cơ chế:** Advanced Self-training & Pseudolabel Refinement
- **Backbone**: SegFormer MiT-B5
- **Student – Teacher** model với **EMA update.**
- **Boundary Head:** một nhánh nhỏ bên cạnh Segmentation Head, học boundary từ source ground truth và dự đoán xác suất một pixel nằm ở interior hay boundary. Thành phần này tồn tại vì boundary thường là vùng khó nhất trong segmentation, có confidence thấp nhưng lại rất quan trọng cho chất lượng mask → Cần phân biệt 1 pixel có là boundary hay không để tinh chỉnh confidence.

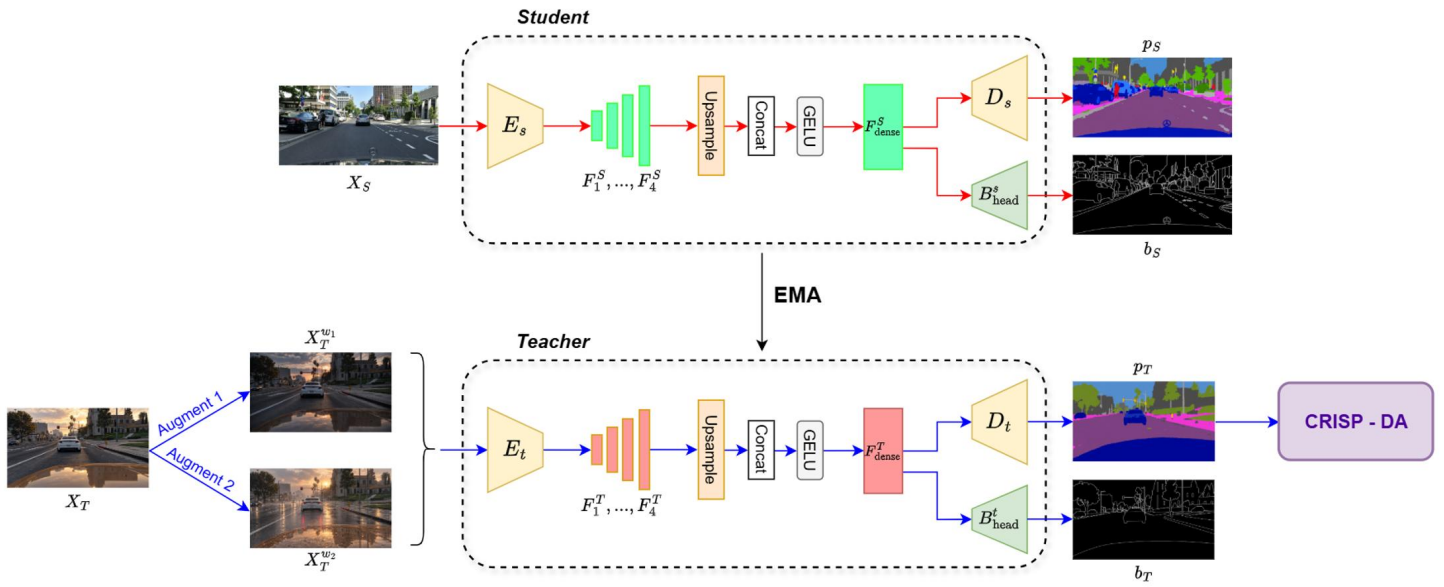


Tổng quan kiến trúc

- **Trên Teacher model:** Target image được chia thành 2 nhánh **augmentation nhẹ**, sử dụng: resize/crop đồng bộ, horizontal flip, mild color jitter hoặc brightness change.

- **Mục tiêu:** đo một loại reliability rất quan trọng - **augmentation consistency** – thông qua Jensen–Shannon divergence.

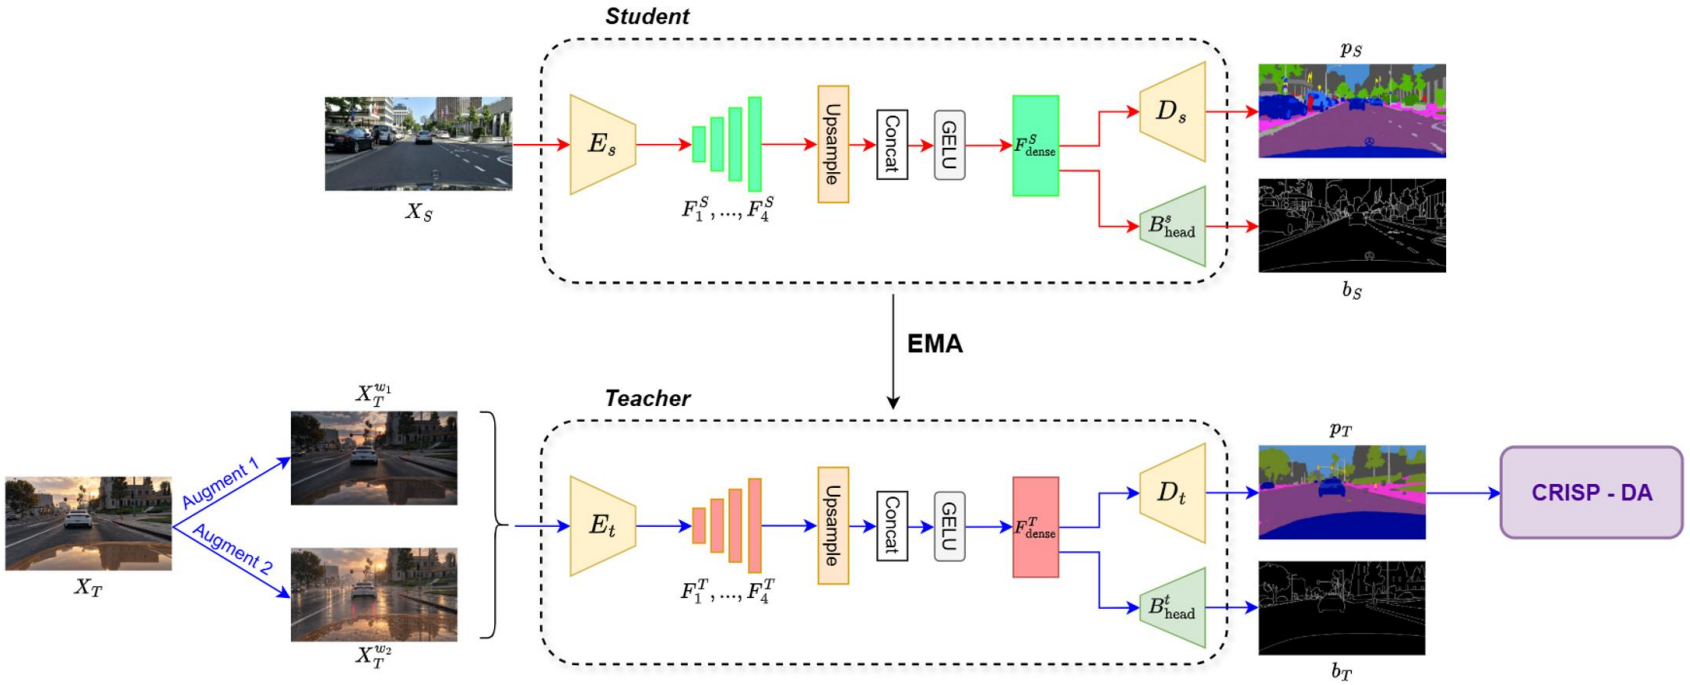
$$a_i = 1 - JS\left(p_i^{T,w_1}, p_i^{T,w_2}\right)$$



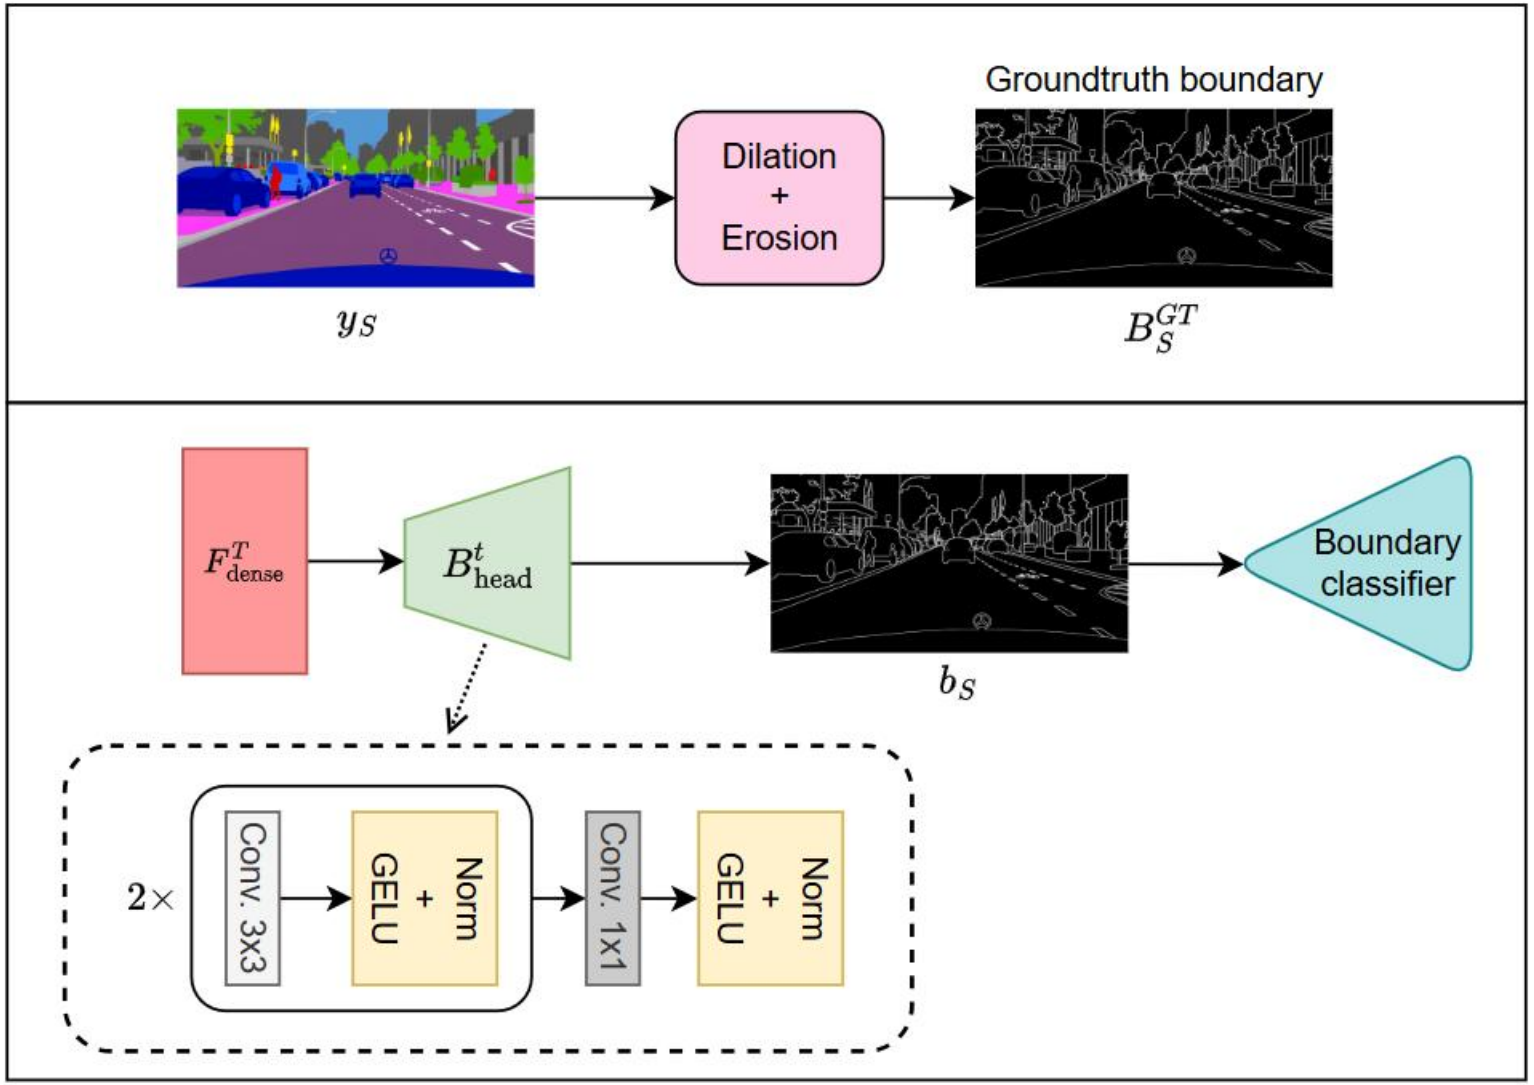
- Áp dụng Augmentation nhẹ để EMA Teacher vừa tạo pseudolabel ổn định, vừa đo augmentation consistency.

Tổng quan kiến trúc

- **Trên Student model:** ảnh target lại sử dụng **augmentation mạnh** → tạo input khó hơn nhưng vẫn giữ semantic class, giúp mô hình Student học được **robustness và invariance** tốt hơn trước các thay đổi về appearance



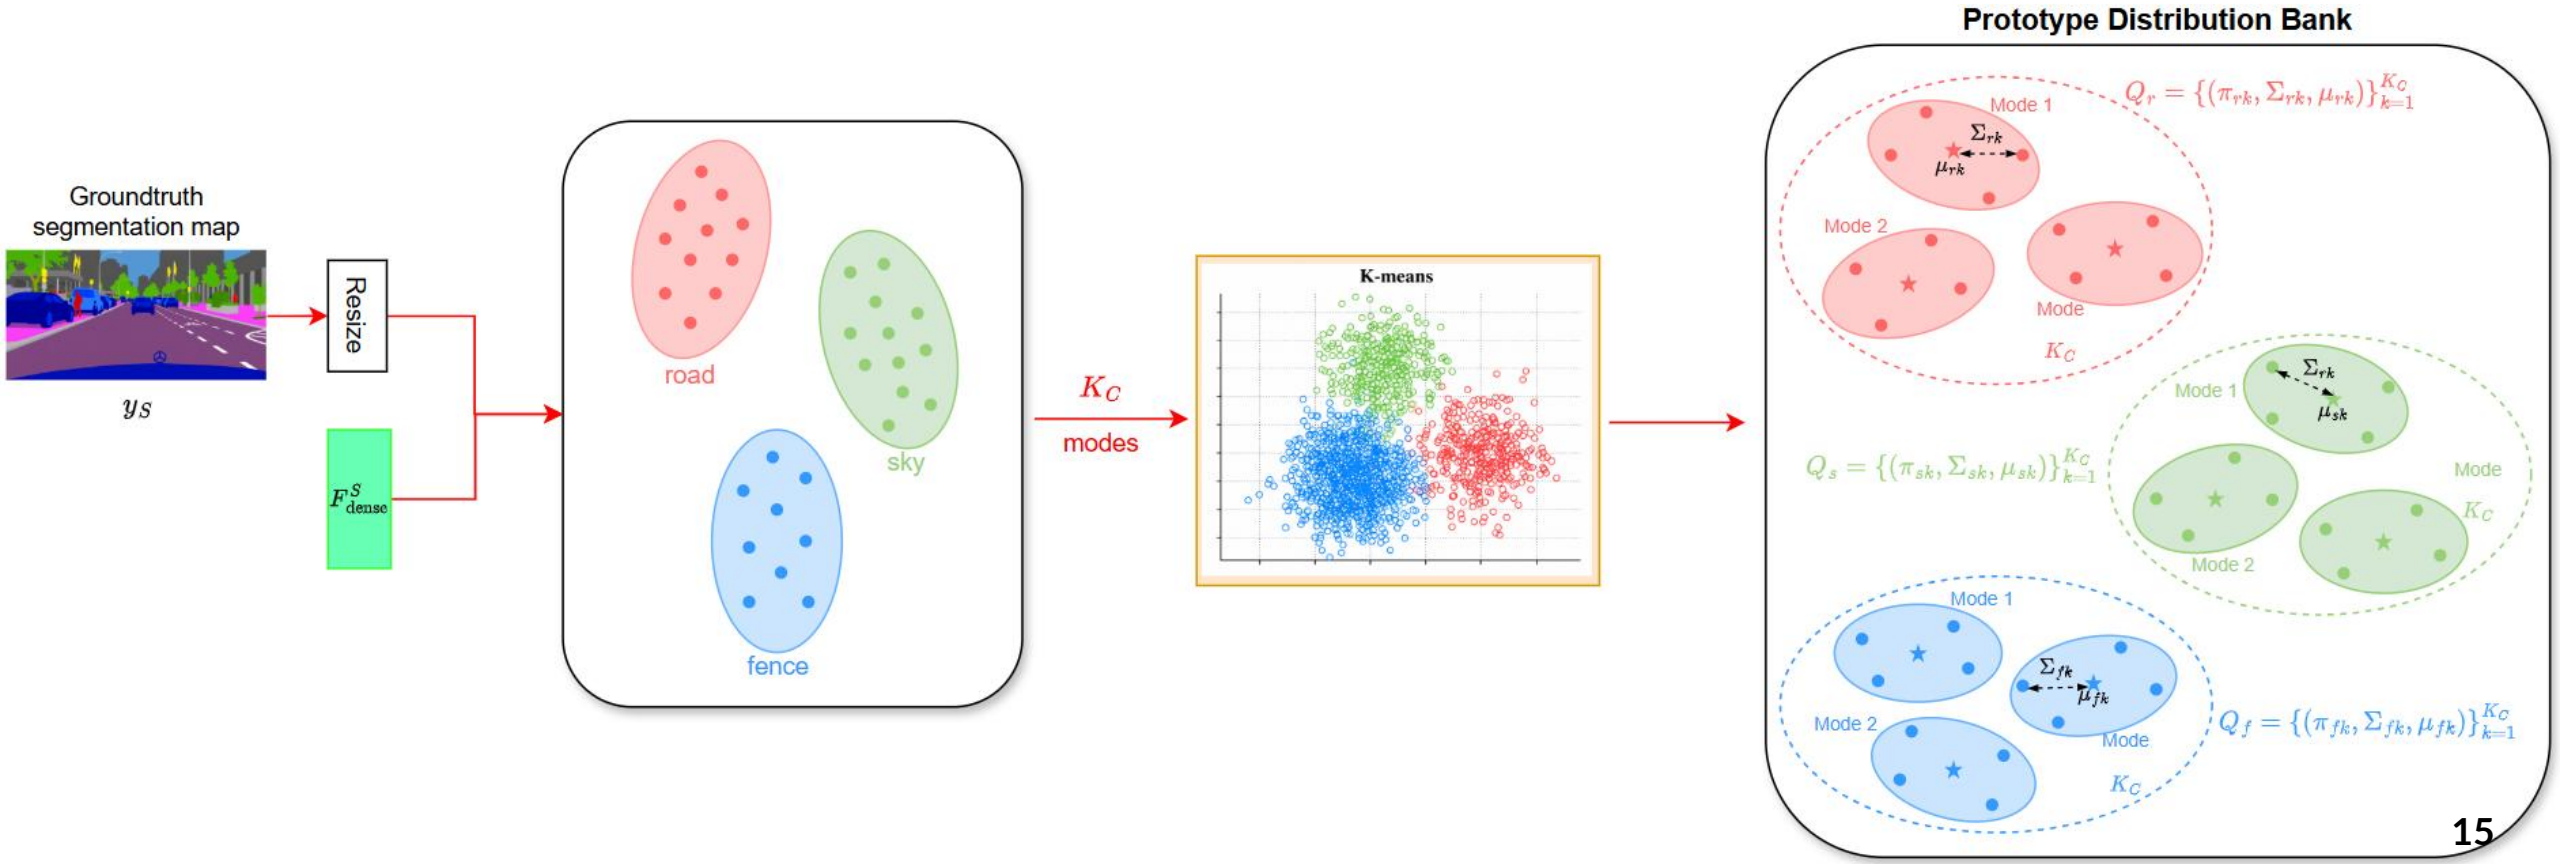
Boundary Head



Class-Conditional Multi-Prototype Distribution Bank

- Bank là memory module, không phải neural network. Nó mô hình hóa mỗi semantic class bằng nhiều mode thay vì một centroid duy nhất.

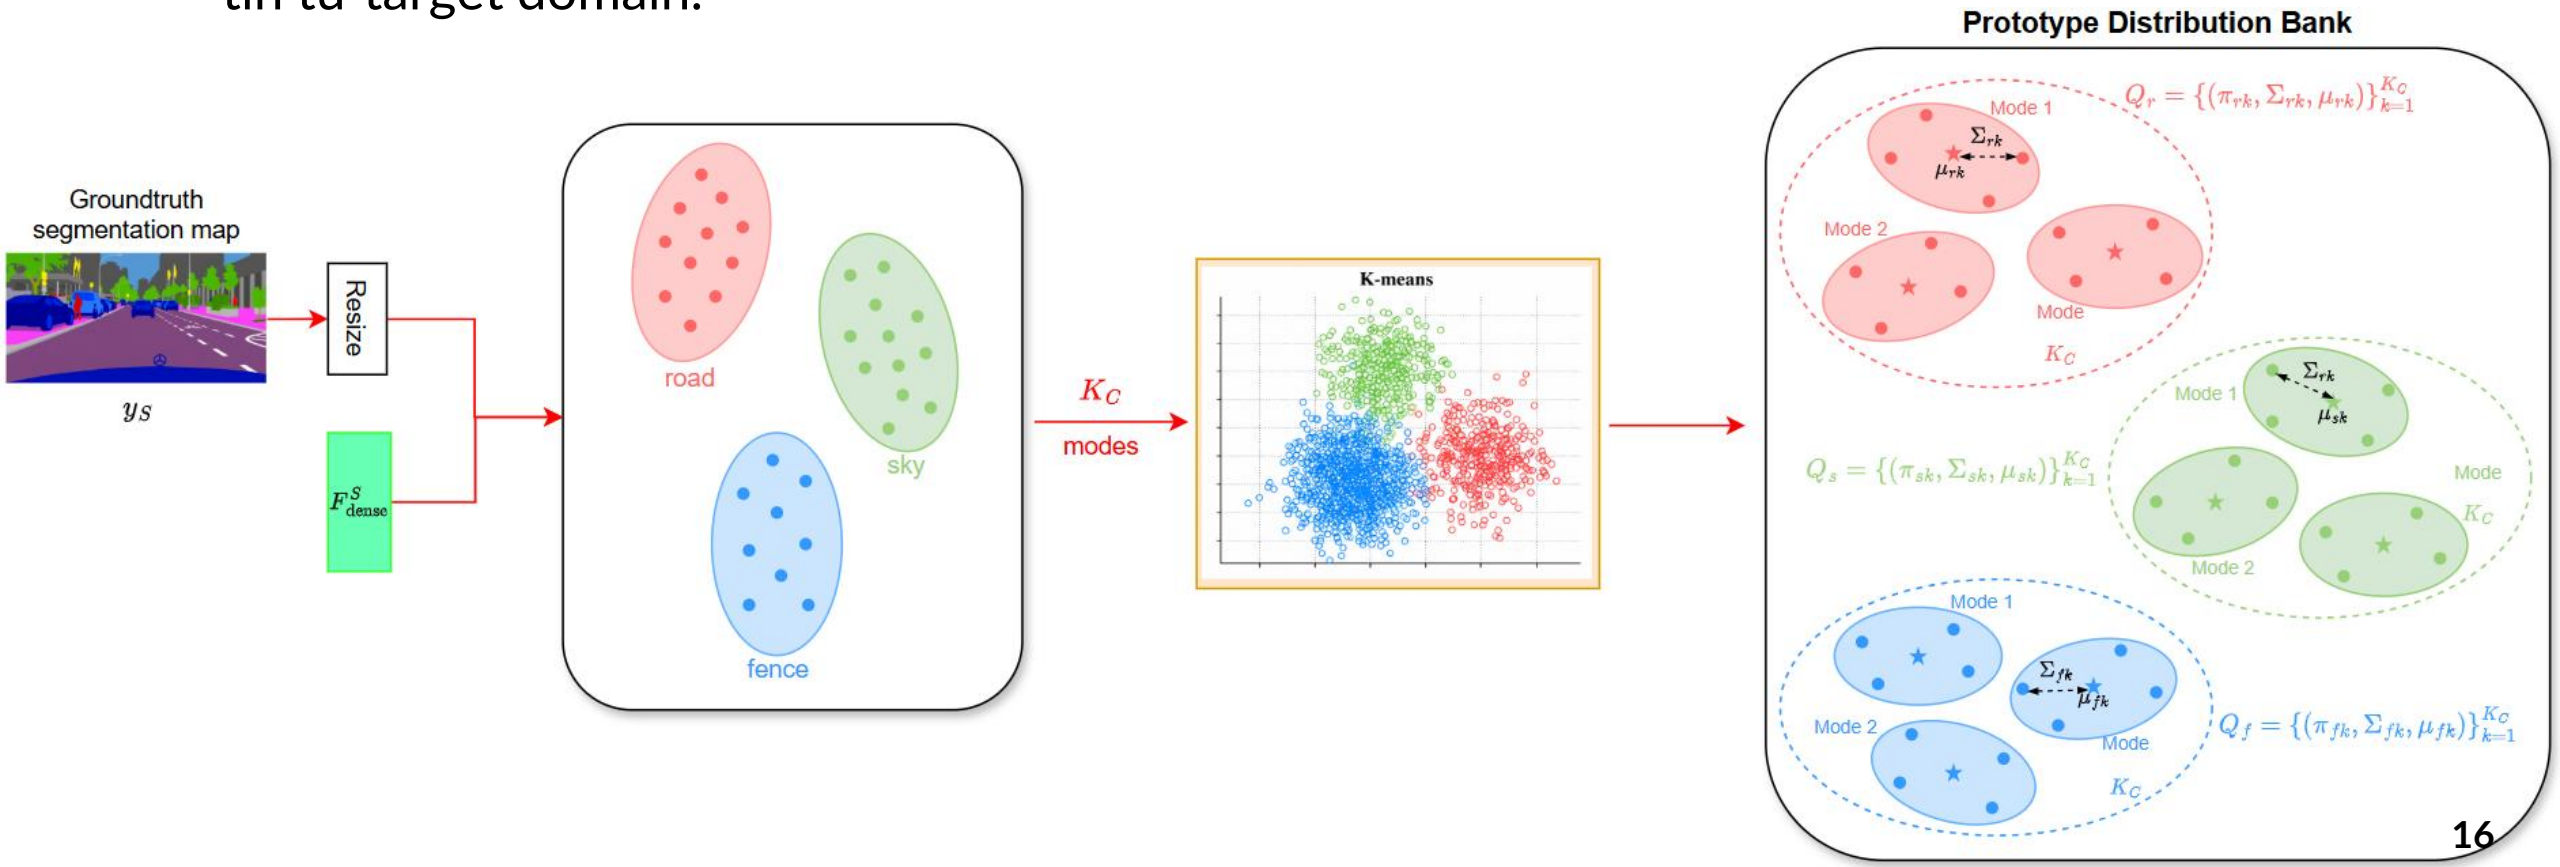
- Mục tiêu là xử lý intra-class multimodality: cùng class có thể thay đổi mạnh theo khoảng cách, ánh sáng, viewpoint, occlusion, thời tiết và domain.



Class-Conditional Multi-Prototype Distribution Bank

- Gaussian mode lưu trong Bank: **Prototype center** μ_{ck}, **Covariance** Σ_{ck} và **Mode weight** π_{ck} (mức độ phổ biến của mode k trong class c)

- **Source initialization** cho Class-Conditional Multi-Prototype Distribution Bank: tạo ra một **semantic reference sạch và ổn định ban đầu** trước khi Bank bắt đầu tiếp nhận thông tin từ target domain.



Class-Conditional Multi-Prototype Distribution Bank

TARGET QUERYING

- Từ target dense feature, xét một feature vector của pixel i. Pixel i được gán class c.

- **Mahalanobis distance** từ target feature tới từng mode:

$$D_{ick} = (f_i^T - \mu_{ck})^\top \Sigma_{ck}^{-1} (f_i^T - \mu_{ck}).$$

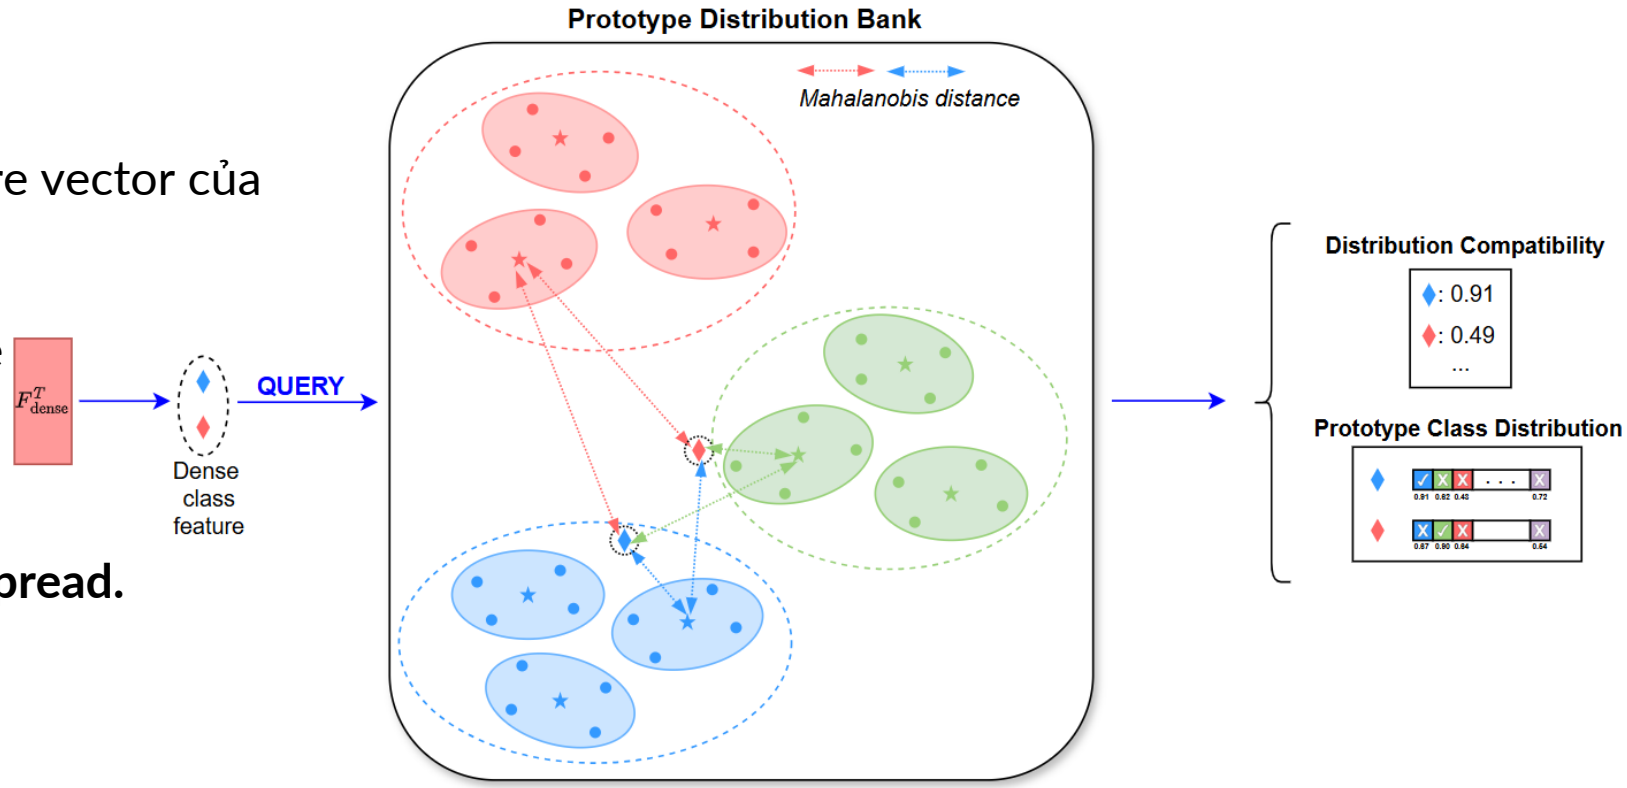
+) Xét cả **prototype center** và **feature spread.**

+) Phù hợp với **multi-modal Gaussian representation.**

+) Xử lý tốt các **mode dị hướng.**

+) Phân biệt tốt hơn feature **gần nhưng bất thường** và **xa nhưng vẫn nằm trong distribution**.

+) Có liên hệ trực tiếp với Gaussian likelihood dùng để tính **distribution compatibility.**



Class-Conditional Multi-Prototype Distribution Bank

TARGET QUERYING

- Lấy mode gần nhất với feature thứ i là D_i^c, và Chuyển thành **Distribution Compatibility** (Teacher model có đang dự đoán class này có hợp lý không?)

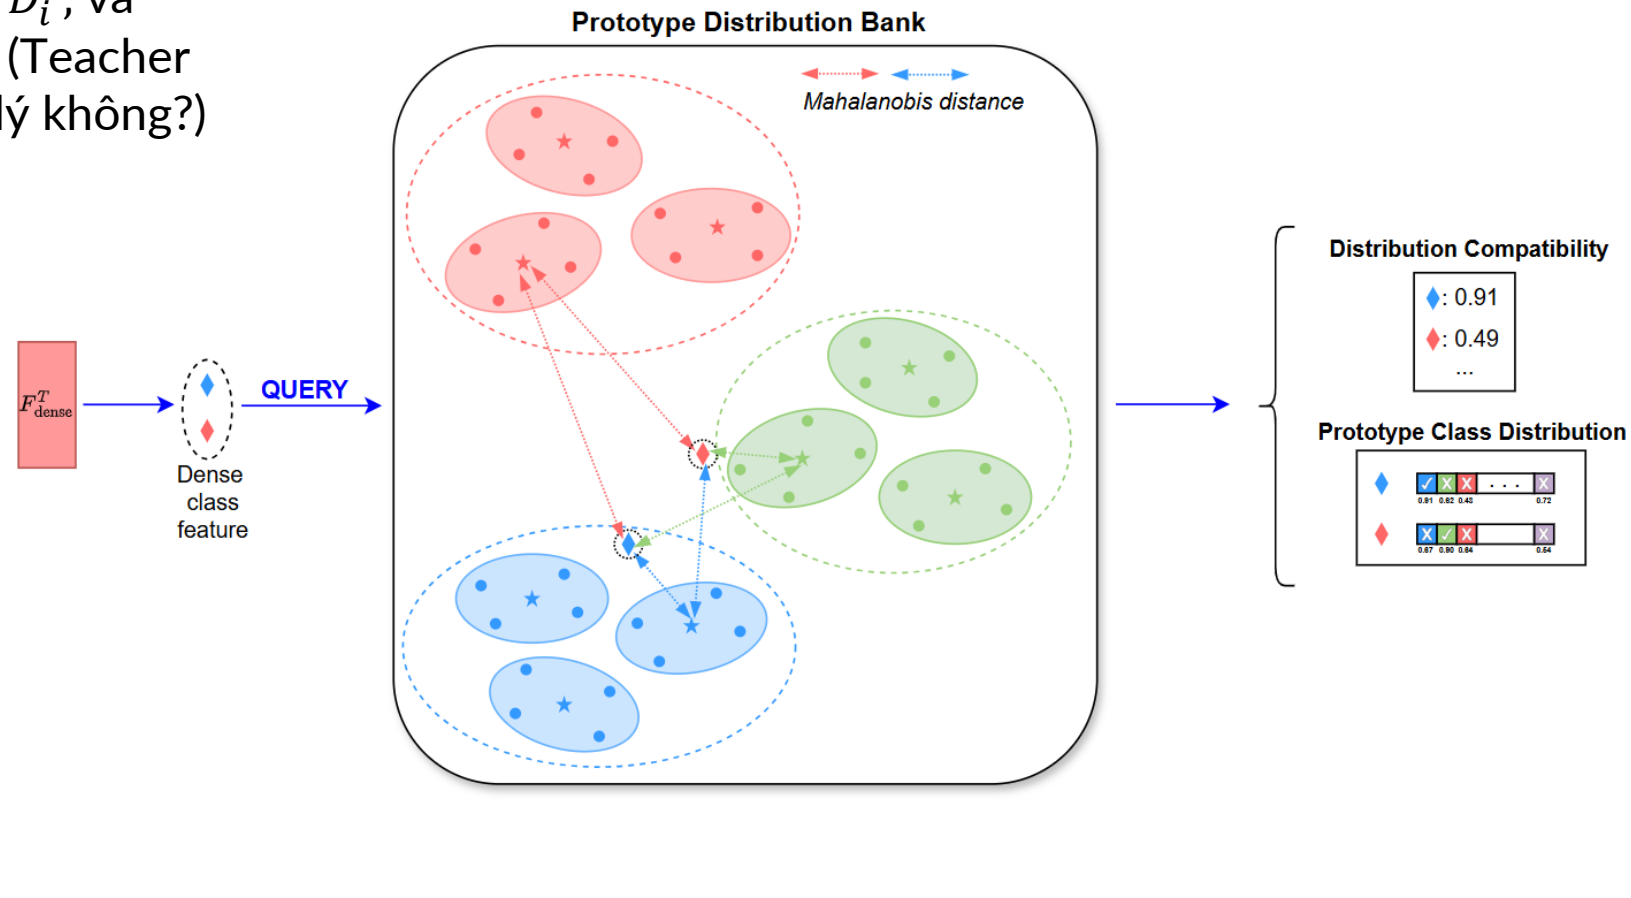
$$d_i = \exp(-D_i^c / T_d) \in (0, 1].$$

- **Prototype Class Distribution** (xét toàn bộ các class, feature này giống class nào nhất?)

$$S_i(c) = \log \sum_{k=1}^{K_c} \pi_{ck} \exp(-\tfrac{1}{2} D_{ick}),$$

$$p_i^{proto}(c) = \text{softmax}_c \, S_i(c),$$

$$c_i^{proto} = \arg\max_c p_i^{proto}(c).$$



Class-Conditional Multi-Prototype Distribution Bank

BANK UPDATE

- Quá trình update bank diễn ra theo 2 giai đoạn training mô hình: **Source-only training** (khởi tạo Bank từ các dense features ở Source) và **Update EMA Student – Teacher** (update them các dense feature ở Target

- Ở mỗi vòng lặp huấn luyện, chỉ những dense feature ở những pixel có **confidence > high_threshold** mới được cập nhật vào Bank.

$$\mathcal{F}^{T,\text{acc}} = \{f_i^T \mid state_i = ACCEPT\}$$

- Với $\mathcal{F}_{ck}^S$ là tập các dense feature ở source thuộc mode k của class c, ta tính batch mean mới:

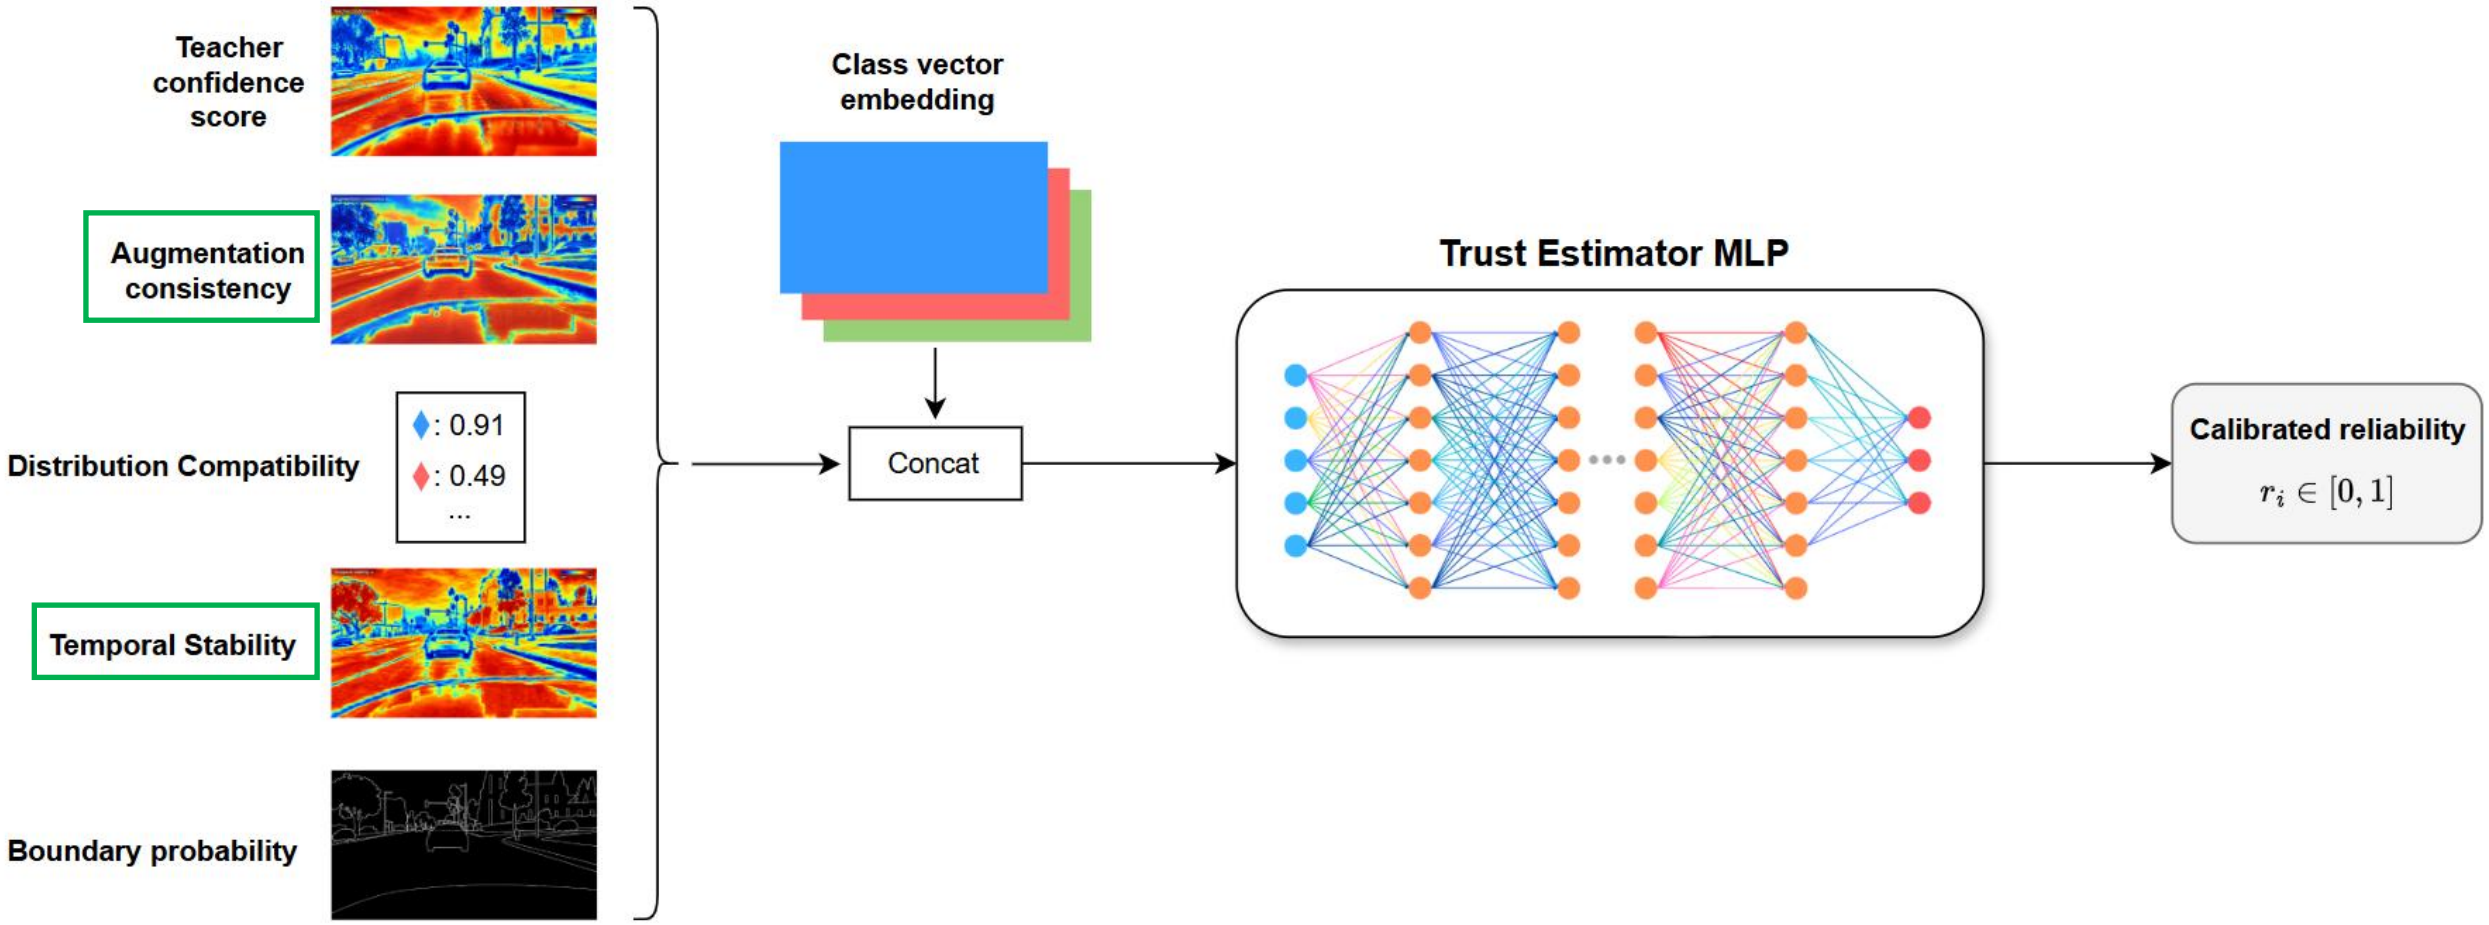
$$\hat{\mu}_{ck} = \frac{\sum_{i \in S_{ck}} f_i^S + \lambda_T \sum_{j \in T_{ck}^{acc}} f_j^T}{N_{S,ck} + \lambda_T N_{T,ck}}$$

Trọng số này < 0.5, để vẫn ưu tiên source GT

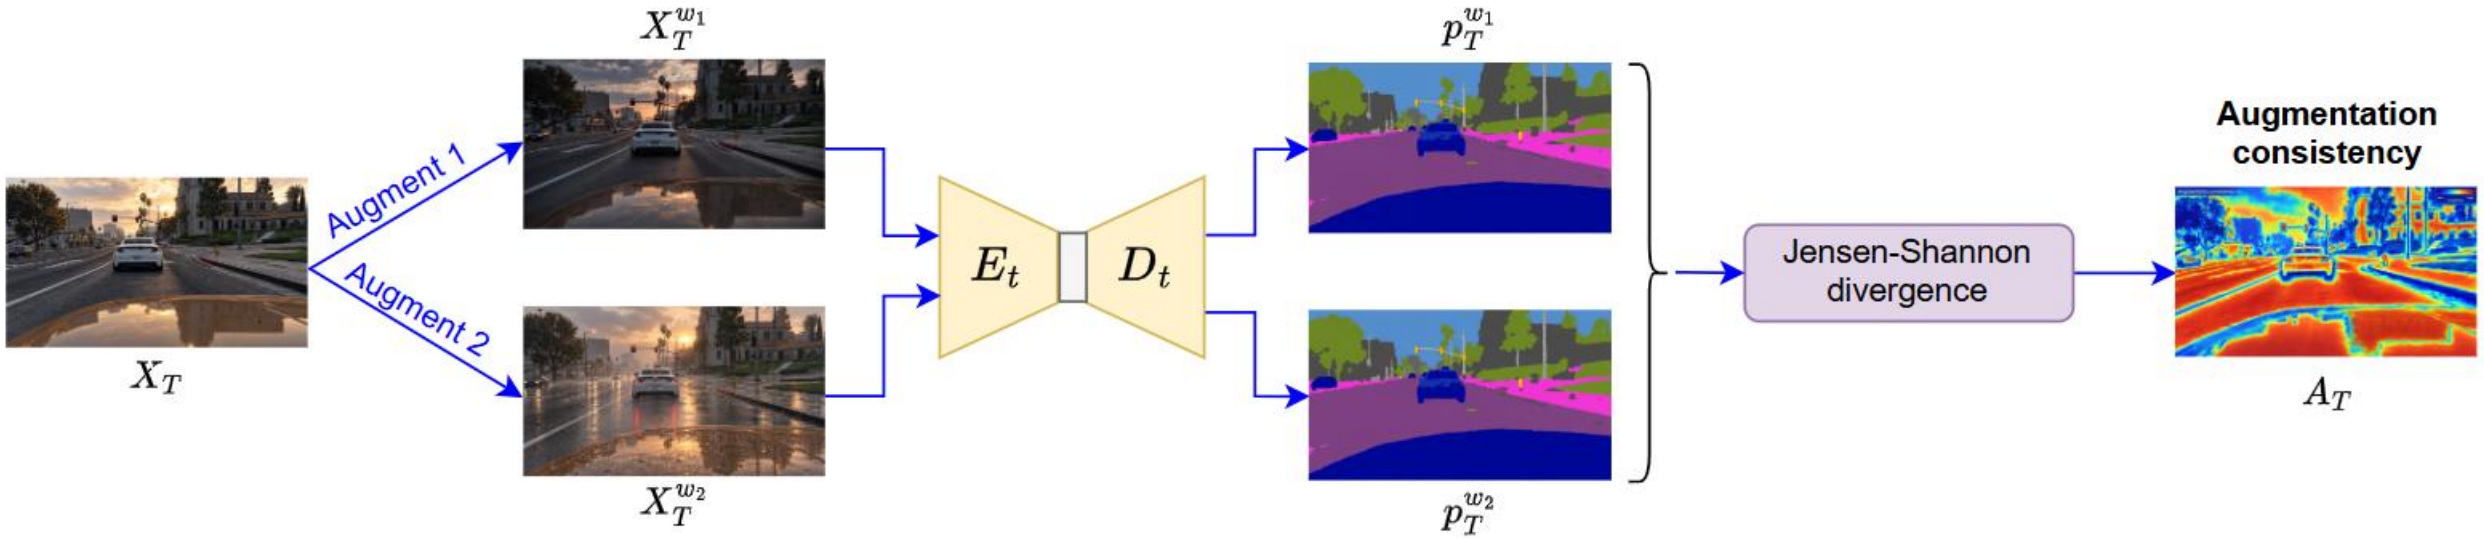
- Sau đó, tiến hành EMA update, để Bank không nhảy mạnh theo một batch mới, mà thay đổi từ từ

$$\mu_{ck}^{(t)} = m\mu_{ck}^{(t-1)} + (1-m)\hat{\mu}_{ck}^{(t)}$$
$$\Sigma_{ck}^{(t)} = m\Sigma_{ck}^{(t-1)} + (1-m)\hat{\Sigma}_{ck}^{(t)}$$
$$\pi_{ck}^{(t)} = m\pi_{ck}^{(t-1)} + (1-m)\hat{\pi}_{ck}^{(t)}.$$

Multi-Evidence Trust Estimator (METE)



Multi-Evidence Trust Estimator (METE)



- **Augmentation consistency a_i:** sử dụng hàm Jensen-Shannon divergence so sánh phân phối của 2 target weak segmentation, và normalize về [0,1].

$$a_i = 1 - \mathrm{JS}(p_i^{T,w_1}, \hat{p}_i^{T,w_2})$$

- $a_i \to 1$ thì prediction càng ổn định qua nhiễu.

Multi-Evidence Trust Estimator (METE)

- **Temporal Stability s_i:** theo dõi quá trình dao động của pseudo-label qua từng vòng huấn luyện.

- Sử dụng EMA Temporal Memory của pseudolabel prediction tích lũy qua từng vòng huấn luyện:

$$M_j^{(t)} = \gamma M_j^{(t-1)} + (1-\gamma) p_j^{T,(t)}$$

$p_j^{T,(t)}$ → Prediction ở iter t của Teacher

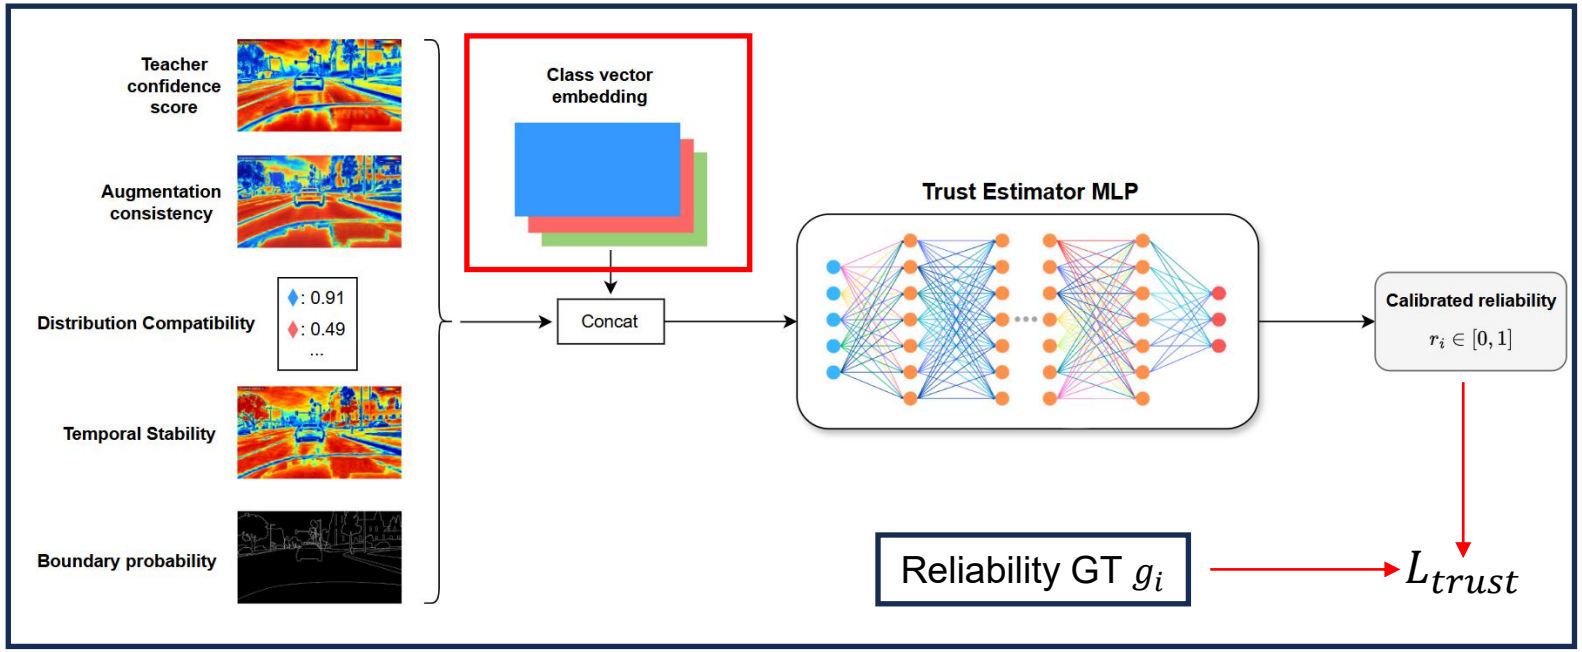
$M_j^{(t-1)}$ → Lịch sử prediction đã tích lũy đến iter $(t-1)$ của pixel j

- Sử dụng EMA Temporal Memory:
  + Giảm nhiễu từ những iteration có dự đoán bất thường
  + Đo được consistency với xu hướng dài hạn nhưng vẫn thích nghi theo training, nhờ hệ số $\gamma \to 1$.

$$s_i = 1 - JS(p_i^{T,(t)}, M_i^{(t-1)})$$

Multi-Evidence Trust Estimator (METE)

Class conditioning: với mỗi pixel i, ta tạo **Class embedding vector** có shape $19 \times d_e$. **(19 classes).**



Training METE trên Source:

- Tạo augmentation cho tập Source → $\widehat{X_s}$
- Từ augmented Source, tạo 5 input cho mạng METE.
- Reliability GT: $g_i = 1$ nếu dự đoán của Teacher cho Source giống Source GT, ngược lại thì $g_i = 0$.
- Class-balance BCE:

$$\mathcal{L}_{\text{trust}} = -\frac{1}{N}\sum_i \left[w_+ g_i \log r_i + w_-(1-g_i)\log(1-r_i)\right].$$

- Gradient của L_{trust} cập nhật backpropagation cho trọng số của **METE** và cập nhật **Class embedding vectors.**

Four-State Pseudo-label Decision (FSPD)

- Module này nhận Pseudolabel thô từ Teacher và các confidence evidence (từ **METE**), và quyết định mỗi pixel được xử lý như thế nào, dựa vào class-wise thresholds $\tau_{high,c}(t)$ và $\tau_{low,c}(t)$.

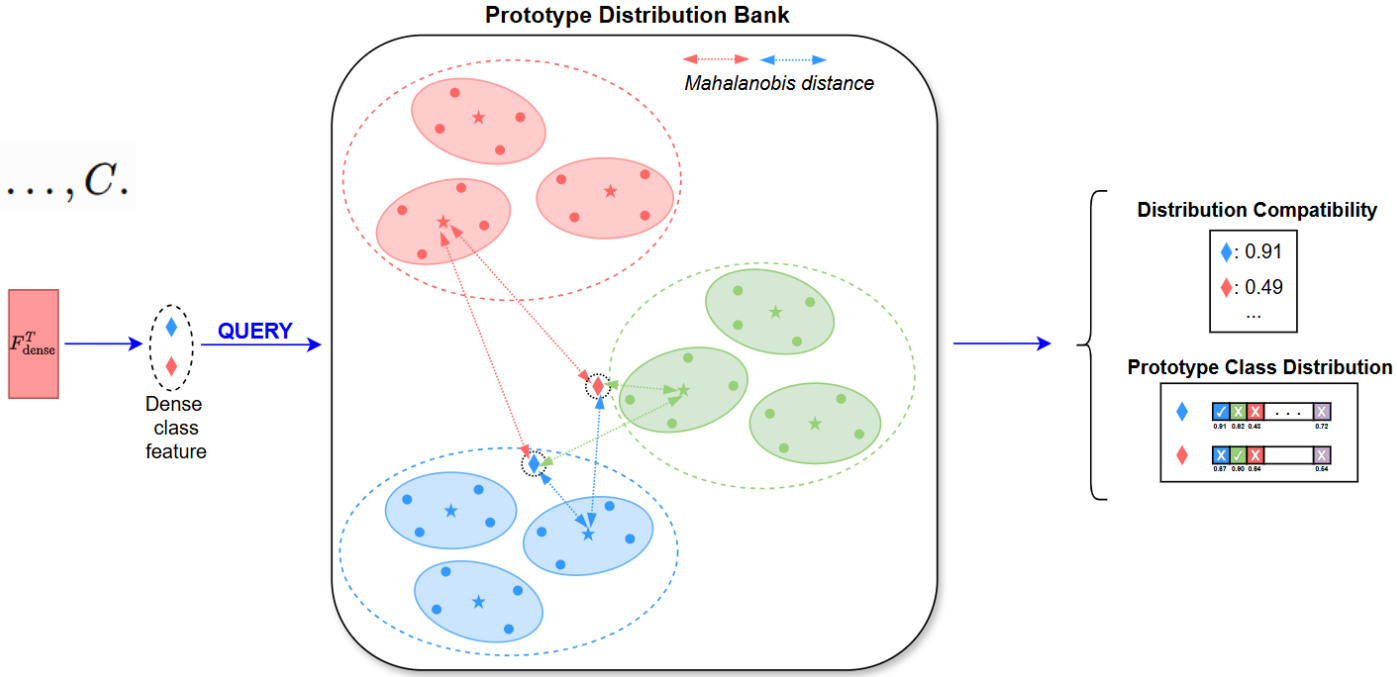
- Logic xử lý: sẽ có 4 trạng thái

  - ❑ **ACCEPT:** Pseudolabel có độ tin cậy cao, được giữ lại
  - ❑ **REVISE:** Sửa pseudo-label sang class khác, khi Teacher prediction chưa đủ tin cậy nhưng có reference đủ tin cậy từ Multi-prototype Distribution Bank.
  - ❑ **SOFT SUPERVISE:** Không đủ chắc chắn để thành hard label nhưng vẫn có ích (nằm giữa 2 ngưỡng threshold)
  - ❑ **ABSTAIN:** tạm thời không dùng pseudo-label khi độ tin cậy quá thấp

Four-State Pseudo-label Decision (FSPD)

Trạng thái ACCEPT:

- **Class Teacher dự đoán:** $c_i^T = \tilde{y}_i^T = \arg\max_c p_{i,c}^T$
- **Prototype bank distribution:** $p_i^{proto}(c), \quad c = 1, \ldots, C.$
- Pseudolabel có Reliability cao: $r_i \geq \tau_{high,c}(t)$
- Prototype Bank có đồng thuận, hoặc không phản đối mạnh với Pseudolabel từ Teacher. Xét p_i^{alt} là xác suất prototype bank của class cao thứ 2 sau c_i^T. Prototype margin:



$$\Delta_i^{proto} = p_i^{alt} - p_i^{proto}(c_i^T)$$

- $\Delta_i^{proto} < 0$: Bank đồng thuận với Teacher
- $0 \leq \Delta_i^{proto} < \delta_{opp}$: Bank không đồng thuận nhưng vẫn nằm trong khoảng cho phép

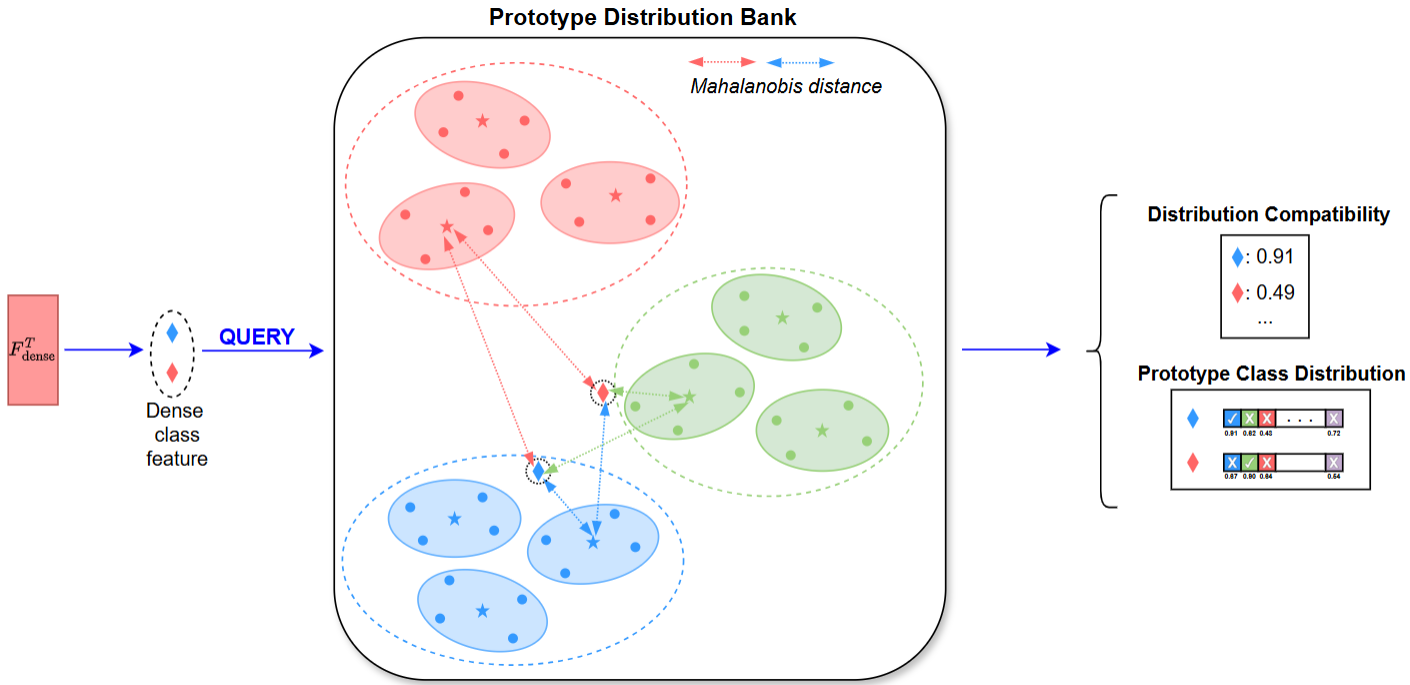
Four-State Pseudo-label Decision (FSPD)

Trạng thái REVISE: Với pixel i

- c_1 , c_2 lần lượt là 2 class có xác suất lớn nhất và lớn thứ 2 trong Prototype Class Distribution của dense feature của pixel i.
- Nhãn giả của pixel: $\tilde{y}_i^T$
- Điều kiện để REVISE – Teacher không đủ đáng tin: $\tilde{y}_i^T \neq c_1, \tau_{low,c}(t) < r_i < \tau_{high,c}(t)$, nhưng Prototype Bank đưa ra một alternative class khác với bằng chứng rất mạnh. (Prototype margin đủ lớn)

$$\Delta_i^{proto} = p_i^{proto}(c_1) - p_i^{proto}(c_2) > \delta_{opp}$$

→ Khi đó, chuyển từ nhãn giả cũ sang class c_1 có xác suất lớn nhất trong Prototype Class Distribution.



Four-State Pseudo-label Decision (FSPD)

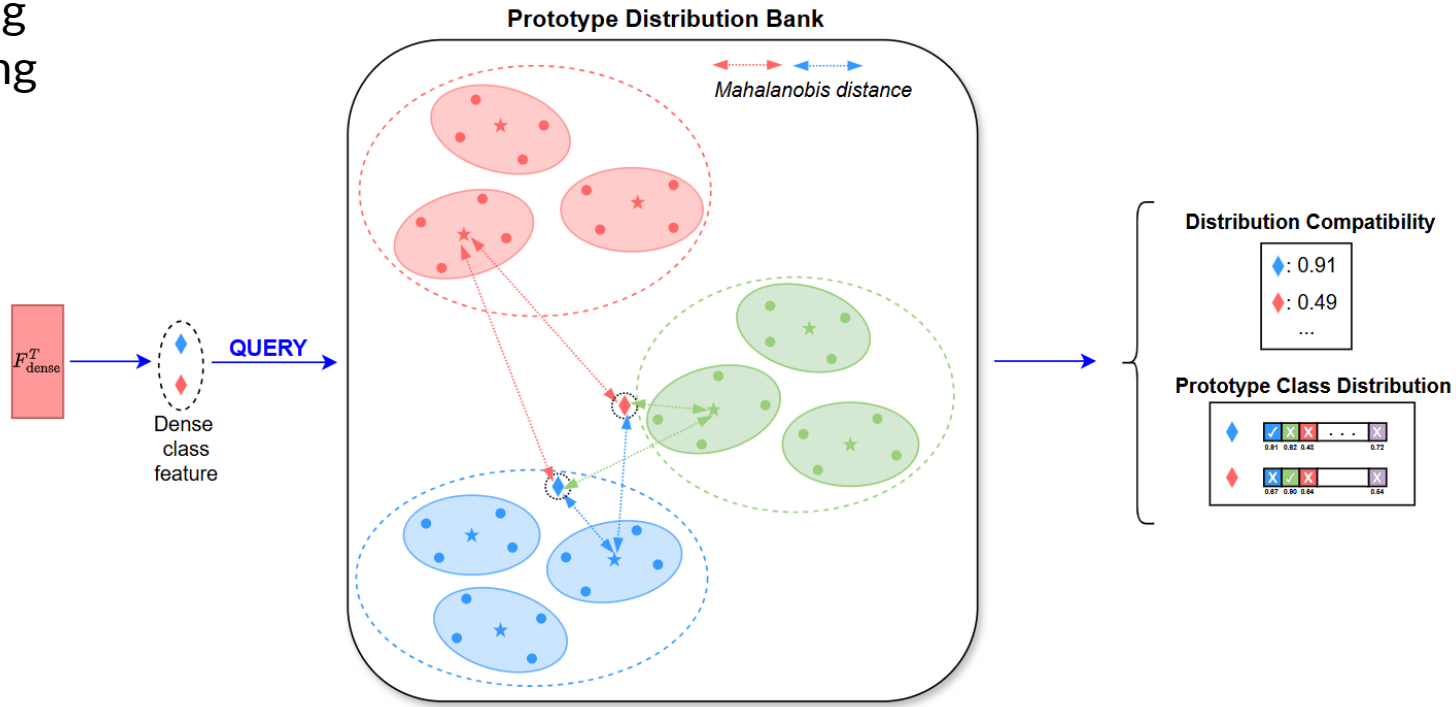
Trạng thái SOFT-SUPERVISE: Với pixel i

- Điều kiện để SOFT-SUPERVISE: Teacher không đủ đáng tin, và thông tin ở Prototype Bank cũng chưa đủ độ tin cậy (Prototype Margin nhỏ hơn ngưỡng cho phép)

$$\Delta_i^{proto} = p_i^{proto}(c_1) - p_i^{proto}(c_2) < \delta_{opp}$$

- Xét p_i^T là Teacher prediction, và p_i^{proto} là Prototype Class Distribution của Bank. Không lấy cứng nhắc theo Teacher hay Bank, ta tạo soft target label:

$$p_i^{soft} = \alpha_i p_i^T + (1 - \alpha_i) p_i^{proto}$$



- Hệ số α_i có thể lấy như sau: để khi nếu Reliability của Teacher r_i cao → nghiêng về Teacher nhiều hơn

$$\alpha_i = \frac{r_i - \tau_{low,c}}{\tau_{high,c} - \tau_{low,c}}$$

Four-State Pseudo-label Decision (FSPD)

Trạng thái SOFT-SUPERVISE: Với pixel i

- Cross-entropy giữa Soft Target và Student Target prediction

$$L_{soft,i} = KL\left(p_i^{soft} \| p_i^S\right)$$

- Hàm loss CE của tất cả pixel ở trạng thái **SOFT-SUPERVISE** có trong Objective Func lúc training Student model → cập nhật trọng số Student

Four-State Pseudo-label Decision (FSPD)

Trạng thái ABSTAIN: Nếu Reliability quá thấp, hoặc Evidence từ Prototype Bank xung đột mạnh, t
loại bỏ pixel nhãn giả đó khỏi quá trình học Teacher

- $r_i \leq \tau_{low,i}(t)$
- $-\Delta_i^{proto} > \delta$ (ngưỡng cho phép tối đa mà **Prototype margin** có thể chạm tới)

(VÍ DỤ: $p_i^T = [road: 0.85, sidewalk: 0.10, car: 0.05]$, $p_i^{proto} = [road: 0.2, sidewalk: 0.75, car: 0.05]$

Khi này, với $\delta = 0.5$, thì $-\Delta_i^{proto} = 0.75 - 0.2 = 0.55 > \delta \rightarrow$ **ABSTAIN**

Balanced Progressive Coverage Curriculum (BPCC)

Module này có nhiệm vụ control 2 ngưỡng threshold $\tau_{high,c}(t)$ và $\tau_{low,c}(t)$ cho module FSPD.

Các thông số trong 1 class c:

- $k_{hard,c}^{(t)}$: Class-wise hard coverage, và $k_{soft,c}^{(t)}$: Class-wise soft coverage

$$\kappa_{hard,c}^{(t)} = \frac{N_{\text{ACCEPT},c}^{(t)} + N_{\text{REVISE},c}^{(t)}}{N_{\text{pred},c}^{(t)}} \qquad \kappa_{soft,c}^{(t)} = \frac{N_{\text{ACCEPT},c}^{(t)} + N_{\text{REVISE},c}^{(t)} + N_{\text{SOFT},c}^{(t)}}{N_{\text{pred},c}^{(t)}}$$

- EMA Average Reliability của class c theo thời gian:

$$\bar{r}_c^{(t)} = \rho \bar{r}_c^{(t-1)} + (1-\rho)\hat{r}_c^{(t)}$$

Balanced Progressive Coverage Curriculum (BPCC)

HIGH THRESHOLD

- Đặt một coverage target thực tế mà BPCC muốn class c đạt được:

$$\kappa^*_{hard,c}(t) = \kappa_{hard,\min,c} + (\kappa_{hard,\max,c} - \kappa_{hard,\min,c})\, g(t)$$

$g(t)$: $\frac{t}{T}$

- $k_{hard,min,c}, k_{hard,max,c}$ là các hyperparameters: mức **coverage mục tiêu thấp nhất** của class c ở **giai đoạn đầu** training, và mức **coverage mục tiêu cao nhất** cho phép class c hướng tới ở **giai đoạn training cuối.**

- Update high threshold: $\tau^{(t+1)}_{high,c} = \left[\tau^{(t)}_{high,c} + \eta_h \left(\kappa^{(t)}_{hard,c} - \kappa^*_{hard,c}(t)\right) + \lambda_h \max\left(0, r_{\min,h} - \bar{r}^{(t)}_c\right)\right]$

Nếu **coverage thực tế hiện tại** đang thấp hơn **target coverage hiện tại** → Threshold giảm xuống → Nhiều pixel dễ vượt qua high threshold hơn → Nhiều pixel được **ACCEPT** với **REVISE** hơn

Giả sử một lớp có coverage đang thấp, muốn giảm threshold nhưng coverage đang thấp hơn mức reliability min → tránh giảm threshold quá đà khi class đang quá unreliable

Objective function & Training

Loss functions

- **Supervised Segmentation loss trên Source:** $L_{sup} = CE(\tilde{y}_S, p_S)$
- **Source Boundary loss (của Boundary Head):** kết hợp cả BCE và Dice (Dice loss để xử lý mất cân bằng vì boundary pixels ít hơn interior pixels rất nhiều)

$$\mathcal{L}_{\text{bd}}^{S} = \mathcal{L}_{\text{BCE}}(B^S, \hat{B}^S) + \mathcal{L}_{\text{Dice}}(B^S, \hat{B}^S)$$

- Hard target loss cho **ACCEPT** và **REVISE** – Gọi A và R lần lượt là tập hợp các pixel thuộc **ACCEPT** và **REVISE**

$$L_{hard} = \frac{\sum_{i \in A} CE(\tilde{y}_i^T, p_i^S) + \omega_R \sum_{i \in R} CE(c_i^{proto}, p_i^S)}{|A| + \omega_R |R| + \epsilon}$$

- Cross-entropy giữa Soft Target và Student Target prediction cho nhãn **SOFT SUPERVISE (Slide 28)**

$$L_{soft,i} = KL\left(p_i^{soft} \| p_i^S\right)$$

Loss functions

- **Weak-to-strong Consistency Loss:** Ép Student model có dự đoán nhất quán ở cả perturbation mạnh và perturbation nhẹ.

Weak augmentation → **EMA Teacher** → $p_i^{T,w}$

Strong augmentation → **Student** → $p_i^{S,s}$

$$L_{cons} = KL(p_i^{T,w} || p_i^{S,s})$$

- **Prototype / Distribution Alignment Loss:** ép feature của Student dịch chuyển vào đúng semantic distribution của Bank. Gọi y_i^* là hard target sau khi **ACCEPT** hoặc **REVISE.**

$$\mathcal{L}_{\text{proto}} = \frac{1}{|\Omega_R|} \sum_{i \in \Omega_R} \min_k D_{i,y_i^*,k}$$

Mahalanobis loss (**Slide 17**)

→ Pixel này thuộc class y_i^*, và kéo feature của nó về mode gần nhất của class đó.

- **Trust Estimator Loss của METE (slide 23)**

Objective Function

- **Objective Function:**

$$\mathcal{L}_{\text{Student}} = \mathcal{L}_{\text{sup}} + \lambda_b \mathcal{L}_{\text{bd}}^{S} + \lambda_h \mathcal{L}_{\text{hard}} + \lambda_s \mathcal{L}_{\text{soft}} + \lambda_c \mathcal{L}_{\text{cons}} + \lambda_p \mathcal{L}_{} + \lambda_r \mathcal{L}_{\text{trust}}$$

Training Curriculum

1. **Source Supervised Warm-up:** Train Student network trên Source GT và train Boundary Head với Source Boundary GT.

2. **Prototype Bank Initialization:** Bank lúc này mới chỉ được xây từ clean labeled source features → Tạo một **stable semantic reference** cho từng class và cung cấp distribution compatibility và Prototype Class Distribution để kiểm tra target pseudo-label sau này.

3. **Trust Estimator Calibration training:** Tạo corrupted source images để mô phỏng prediction errors/domain shift, tạo các input và embedding vectors và tạo GT source → Train bằng L_{trust} **(Slide 23)**

4. **Conservative Target Adaptation:**
   - Khởi tạo EMA Teacher từ Student và cập nhật trọng số Teacher model. Teacher nhận Target weak augment, còn Student nhận Target strong augment
   - Target dense feature đưa qua query Prototype Distribution Bank (CHƯA UPDATE)
   - Tính Calibrated Reliability r_i → FSPD tìm trạng thái nhãn giả
   - Student học qua objective function nhưng chỉ tính trên Source

Training Curriculum

5. **Full CRISP-DA Adaptation:**
   - Student được train với tổng Objective trên target images.
   - Những target feature thuộc ACCEPT hoặc REVISE ở giai đoạn sau sẽ được cập nhật EMA vào Bank
   - Dịch chuyển Bank từ source-centered distribution sang target-adapted semantic distribution.
   - Khai thác đầy đủ hard correction, soft supervision và feature alignment

6. **BPCC update thresholds sau mỗi một vòng iteration**