RESEARCH ENGINEERING / UDASS / VERSION 1.0

CRISP-DA IMPLEMENTATION PLAN

Kiến trúc end-to-end • Thiết kế objective • Quy trình training • Lộ trình Source-only → Baseline → Full CRISP-DA

01
SOURCE-ONLY
Supervised CE

>

02
EMA BASELINE
Keep / Ignore

>

03
CRISP-DA
Multi-evidence + policy

MỤC ĐÍCH Tài liệu này chuyển hai nguồn PDF thành một bản đặc tả đủ cụ thể để phân chia modules, định nghĩa tensor contracts, lập trình PyTorch, tạo unit tests và tổ chức thí nghiệm. Không phải tài liệu báo cáo kết quả đã được kiểm chứng.

Nguồn căn cứ	Vai trò trong Implementation Plan
[F] CRISP_DA_full(1).pdf, 33 trang	Nguồn chính: mục 4-19 cho modules, tensor I/O, loss, training; mục 20-27 cho inference, ablation và checklist.
[S] CRISP-DA_Part1(1).pdf, 37 slides	Nguồn bổ trợ về sơ đồ architecture, Boundary Head, Bank, MTE, Four-State Policy, loss và training curriculum.

Quy ước: [SOURCE] = đúng theo hai PDF; [DECISION] = lựa chọn triển khai được đề xuất để code thống nhất; [OPEN] = chưa được hai PDF cố định, cần đánh giá thực nghiệm. Ký hiệu B=batch, C=19, H/W=kích thước crop, h=H/4, w=W/4, D=256.

Định hướng sử dụng: ưu tiên tái hiện baseline và giữ checkpoint/results tách biệt; khi mở rộng CRISP-DA, bật từng module theo ablation, không thay đổi ngầm protocol so sánh.

Mục lục triển khai

Phần	Nội dung chính
01	Scope, datasets, milestones và tensor conventions
02	Sơ đồ computational graph end-to-end, giao diện modules
03	Student MiT-B5, dense projector, segmentation head, EMA Teacher
04	Boundary Head, multi-prototype Distribution Bank, temporal memory
05	Multi-Evidence Trust Estimator, Four-State Policy, BPCC
06	Toàn bộ eight-loss objective và gradient routing
07	Training iteration, warm-up, scheduling, inference
08	Implementation roadmap: Source-only → EMA Baseline → CRISP-DA
09	Repository design, tests, Molab integration, checkpoints
10	Ablations, evaluation, unresolved choices, sign-off criteria

01 / Phạm vi, datasets và nguyên tắc kiến trúc

CRISP-DA giải quyết **closed-set Unsupervised Domain Adaptation for Semantic Segmentation** với source labeled **GTA5** và target unlabeled **Cityscapes**. Hệ thống được thiết kế để nâng chất lượng pseudo-label bằng reliability estimation đa bằng chứng, structured supervision và class-balanced progressive coverage. [F §1–3; S slides 4–8]

Dữ liệu	Training/evaluation	Output của loader
GTA5 source train	Ảnh và segmentation ground truth; remap label sang 19 train IDs.	image float[B,3,H,W], mask long[B,H,W], image_id
Cityscapes target train	Chỉ dùng ảnh không nhãn trong optimization (teacher/student).	image float[B,3,H,W], image_id, transform_meta
Cityscapes val	Benchmark evaluation với GT; **không** đưa target GT vào loss, Bank hoặc Trust training.	image, mask trainIds, file_name

- Trước training: xác nhận **19-class mapping**, ignore_index=255, source/target preprocessing nhất quán, phân chia train/val đúng protocol, RGB normalization phù hợp pretrained checkpoint.
- Khi augmentation ảnh và mask: image bilinear interpolation, integer label dùng nearest-neighbor; các transform hình học phải được đồng bộ cho mọi target/probability/mask liên quan.
- Nên thiết kế đường dẫn dataset qua config, không hardcode Google Drive/Molab paths trong mô hình.

PHÂN BIỆT CÁC GIAI ĐOẠN Ba giai đoạn **Source-only → EMA Baseline → CRISP-DA** là kế hoạch code và so sánh thí nghiệm. Bên trong giai đoạn Full CRISP-DA vẫn có preprocessing, source bootstrap, conservative adaptation và full adaptation; không nên đánh đồng hai cấu trúc này.

01.1 / Tensor conventions và hợp đồng toàn hệ thống

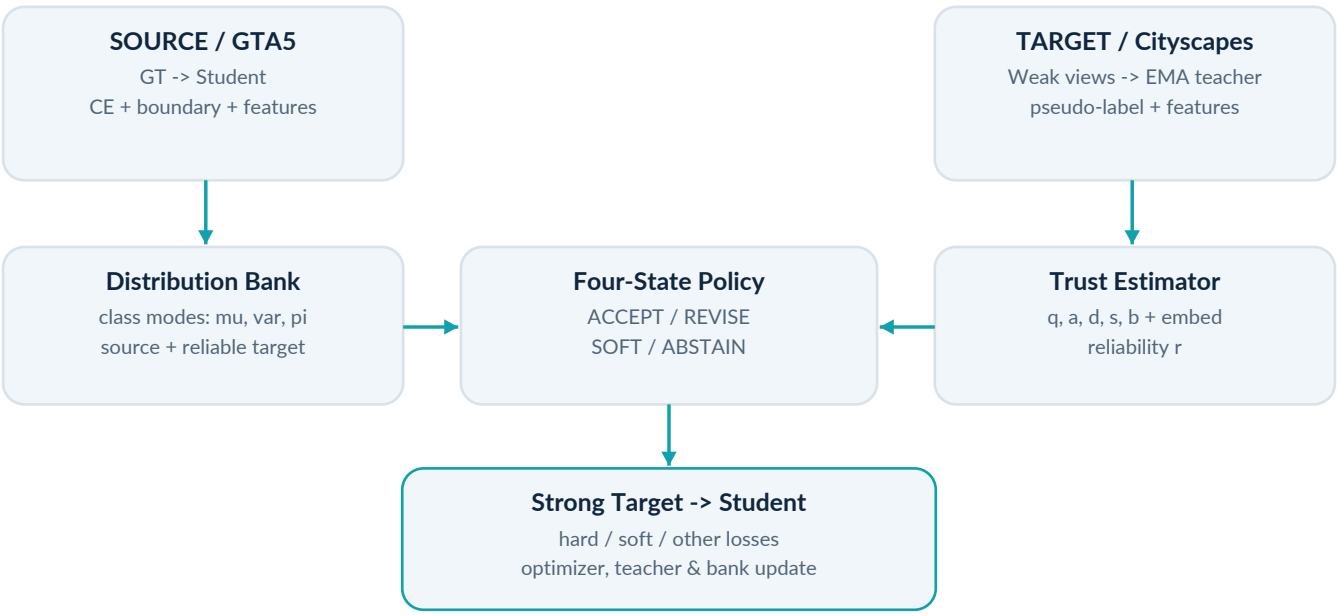
Tensor	Shape	Ý nghĩa / nơi dùng
xs / xt	[B,3,H,W]	Source / target RGB normalized
ys	[B,H,W]	Source IDs 0..18, ignore=255
F1, F2	[B,64,h,w] / [B,128,h/2,w/2]	Transformer feature pyramids
F3, F4	[B,320,h/4,w/4] / [B,512,h/8,w/8]	Feature pyramids deeper stages
Fdense	[B,256,h,w]	Bank query; student representation; boundary
z / p	[B,19,H,W]	Segmentation logits and per-class softmax
q,a,d,s,b,r	[B,1,h,w]	Five evidence maps and reliability
Pproto / Psoft	[B,19,h,w]	Prototype posterior / refined soft target
MA/MR/MS/MX	[B,h,w] bool	Mutually exclusive state masks

Bảng shape giả định H,W chia hết cho 32; mọi branch phải sử dụng coordinate alignment và valid-region mask khi crop/padding. [F §4.4, §18]

02 / Luồng end-to-end và dependency graph

Luồng xử lý nên tách thành ba nhánh: source supervision; target teacher → evidence → policy; student target strong-view → losses. Các tham số neural được cập nhật bằng optimizer, còn EMA Teacher, Prototype Bank, Temporal Memory và BPCC là state ngoài gradient. [F §4, §14]

Two-domain self-training: non-gradient memory / controller around gradient-trained Student



Sơ đồ khái niệm (không biểu diễn thứ tự topology chính xác của mọi mũi tên phụ): source tạo Bank và supervised losses; teacher tạo evidence; policy điều khiển target supervision và update gate.

Khối	Nhận input	Trả output	Cập nhật
Student	source / strong target image	logits, Fdense	Gradient: Lsup, Lhard, Lsoft, Lcons, Lproto
Boundary Head	source/target Fdense	boundary probability	Gradient: source/target boundary loss
EMA Teacher	two weak target views	raw label, pT, FT, boundary optional	EMA sau optimizer
Bank	source/target detached feature + labels	d, Pproto, centers/variances/weights	Running stats EMA; gated target
Trust estimator	q,a,d,s,b,class embedding	r[0,1]	Gradient: source calibration BCE
Four-State Policy	r,pT,Pproto,thresholds	Yhard,Psoft,masks,weights	Rule only
BPCC	coverage, r, class, step	tau_high[c],tau_low[c]	Statistics/controller

IMPLEMENTATION CONTRACT Không được dùng raw pseudo-label trực tiếp làm training target của full CRISP-DA trước khi qua Four-State Policy. Teacher và Bank không thuộc optimizer. Khi một iteration kết thúc mới update Bank từ features đã detach và được policy cho phép.

03 / Student Segmentation Network: layer-level blueprint

03.1 / MiT-B5 encoder: canonical stage specification

Hai nguồn dùng **SegFormer MiT-B5** pretrained. Bốn hierarchical transformer stages sinh feature maps đa độ phân giải, sau đó decoder chiếu về 256 channels. Số block, embed dims, attention heads và spatial-reduction ratios dưới đây lấy từ [F §5.3].

Stage	Patch / stride	Output channels	Depth	Heads	SR ratio	Output res.
1	7 / 4	64	3	1	8	H/4 × W/4
2	3 / 2	128	6	2	4	H/8 × W/8
3	3 / 2	320	40	5	2	H/16 × W/16
4	3 / 2	512	3	8	1	H/32 × W/32

Block/Layer contract: từng stage gồm overlapping patch embedding, chuỗi transformer blocks với efficient multi-head self-attention (K/V spatial reduction theo SR ratio), Mix-FFN và normalization, cuối stage đưa kết quả về feature map. **[DECISION]** Nên dùng một thư viện implementation SegFormer/MiT-B5 đã kiểm thử cho từng attention/FFN internal, thay vì tự giả định thêm hidden dimensions hoặc bias/config mà hai PDF không quy định. Như vậy encoder shapes vẫn đúng và có thể load pretrained weights.

Module con	Input → output	Mô tả coding
Overlap patch embed	image/tensor → tokens at lower res	Conv(kernel/stride theo bảng) → flatten/spatial tokens → LayerNorm; sau stage reshape lại map.
Efficient attention	tokens → tokens, giữ channels	Multi-head Q attention; K/V qua spatial reduction; residual with normalization.
Mix-FFN	tokens → tokens	Pointwise expansion → depthwise spatial interaction → activation → projection; residual.
Output norm	tokens → F1..F4	Stage-specific norm; reshape B×C×Hi×Wi theo stage.

OPEN: THAM SỐ NỘI BỘ MiT Các PDF cho stage depths/dimensions/heads/SR/patch nhưng **không liệt kê toàn bộ tham số của từng internal MLP, attention bias, dropout, padding**. Plan yêu cầu khóa phiên bản thư viện, checkpoint pretrained và in model summary; chi tiết thực tế phải theo implementation/weight tương ứng, không tự nhận là thông số gốc.

03.2 / Dense projector và fusion

Layer	Tensor sau layer	Ghi chú
Project P1(F1): 1×1 Conv 64→256	[B,256,H/4,W/4]	Spatial scale gốc
Project P2(F2): 1×1 Conv 128→256	[B,256,H/8,W/8]	Bilinear → H/4,W/4
Project P3(F3): 1×1 Conv 320→256	[B,256,H/16,W/16]	Bilinear → H/4,W/4
Project P4(F4): 1×1 Conv 512→256	[B,256,H/32,W/32]	Bilinear → H/4,W/4
Concat(P1,up P2,up P3,up P4)	[B,1024,H/4,W/4]	Concatenate theo channels
Fusion Conv1×1 1024→256 + Norm + GELU	[B,256,H/4,W/4]	Fdense: common input cho heads/bank

$$Fcat = Concat(P1(F1), up(P2(F2)), up(P3(F3)), up(P4(F4)))$$

$$Fdense = GELU(Norm(Conv1x1_1024to256(Fcat)))$$

03.3 / Segmentation Head

Thứ tự	Operation	Tensor
1	3×3 Conv, 256→256	[B,256,h,w]
2	Normalization + GELU	[B,256,h,w]
3	Dropout(p=0.1)	[B,256,h,w]
4	1×1 Conv, 256→C (C=19)	[B,19,h,w]
5	Bilinear upsample → H×W	[B,19,H,W]
6	Softmax(dim=class) khi cần probability	[B,19,H,W]

Trong training, **CrossEntropyLoss nhận logits**, không softmax trước. Head trả cả logits và fused feature để về sau thêm Bank/MTE; các training scripts Source-only và Baseline có thể chỉ sử dụng logits.

03.4 / Code interface và smoke tests

```
def student_forward(images: Tensor) -> dict:
    # images: float [B, 3, H, W]
    return {"logits": logits,              # [B, 19, H, W]
            "dense_features": Fdense,       # [B, 256, H/4, W/4]
            "multi_scale": (F1,F2,F3,F4)}

assert outputs["logits"].shape == (B, 19, H, W)
assert outputs["dense_features"].shape == (B, 256, H//4, W//4)
```

- Test 1: 19-class logits shape, all finite; Test 2: loss.backward() tạo gradient lên encoder, projector, head; Test 3: checkpoint pretrained load khớp missing/unexpected keys dự kiến; Test 4: ignore_index=255 không gây lỗi CE.

04 / EMA Teacher và augmentation alignment

04.1 / Kiến trúc Teacher

Teacher là bản sao encoder + dense projector + segmentation head của Student; full mode có thể mirror Boundary Head. Teacher nhận **hai weakly augmented target views**, sinh pT,w1, pT,w2, raw labels y_raw và FT. Teacher ở eval mode trong pseudo-label forward để tránh nhiễu từ dropout; không dùng gradients. [F §6; S slides 10–13]

theta_teacher := alpha * theta_teacher + (1-alpha) * theta_student; alpha≈0.999

```
@torch.no_grad()
def ema_update(teacher, student, momentum=0.999):
    for t, s in zip(teacher.parameters(), student.parameters()):
        t.mul_(momentum).add_(s, alpha=1.0-momentum)
    # Buffer policy (e.g. BN stats) must be fixed in implementation.
```

[DECISION] Định nghĩa chính sách cập nhật buffers rõ ràng (nếu dùng BatchNorm thì cập nhật/copy running statistics phù hợp); không chỉ EMA trainable parameters rồi bỏ quên state buffers. Pretrained Student sau source-only là điểm khởi tạo Teacher cho EMA Baseline.

04.2 / Weak versus strong views

View	Dùng cho	Phép biến đổi theo hai nguồn
Teacher weak #1	#1 pseudo-label + dense target feature	Synchronized resize/crop/flip; mild brightness/contrast/color jitter
Teacher weak #2	Augmentation consistency	Same geometric frame hoặc record invertible transforms; mild photometric noise
Student strong	Target hard/soft supervision	Strong color jitter, blur, masking; optional ClassMix/CutMix; geometric warp của target/masks

- Bắt buộc dùng transform metadata để align xác suất và mask. Nếu sử dụng hai weak views khác geometry, inverse-warp mỗi probability map về canonical coordinates và so sánh trên valid overlap.
- Bắt đầu baseline đơn giản bằng shared geometry + photometric-only strong augmentation, sau đó thêm crop/flip/resize đa dạng khi alignment tests đã đạt.

TEST QUAN TRỌNG Identity warp phải bảo toàn distribution và labels; horizontal flip hai lần cho mask/probability phải khôi phục giá trị; labels chỉ nội suy nearest, distributions dùng bilinear và renormalize theo class nếu cần.

05 / Boundary Head: full CRISP-DA module

Boundary Head nhận Fdense và trả bản đồ xác suất nằm gần semantic boundary. Đây là nhánh bổ trợ cho source boundary loss, target boundary loss và spatial evidence b. [F §7; S slide 14]

Thứ tự	Layer / operation	Output
1	Conv3×3, 256→128; Norm; GELU	[B,128,h,w]
2	Conv3×3, 128→64; Norm; GELU	[B,64,h,w]
3	Conv1×1, 64→1	[B,1,h,w] logits
4	Bilinear upsample + Sigmoid	[B,1,H,W] probability b

Source boundary GT: tạo binary band từ segmentation GT bằng morphological dilation - erosion hoặc contour extraction; band 3–5 pixel là ví dụ trong nguồn. Phải mask pixels ignore/invalid. **Source objective:** BCE + λ_D Dice. Khi dùng EMA boundary prediction cho target, copy/EMA head tương ứng sang Teacher.

[DECISION] Nên trả boundary_logits trước sigmoid để tính BCEWithLogitsLoss ổn định số; chỉ dùng sigmoid probability cho evidence và visualization. Quyết định upsample logits trước sigmoid cần giữ nhất quán.

PHASE GATE Không thêm Boundary Head vào thí nghiệm Source-only hay EMA Baseline **nếu mục tiêu là baseline tối giản**. Với full CRISP-DA bật module này sau khi V1 trust/bank/policy chạy ổn định để ablation rạch ròi.

06 / Class-Conditional Multi-Prototype Distribution Bank

06.1 / State, geometry và kiểu dữ liệu

Bank là **non-parametric memory**, không phải learned head. Mỗi class giữ K=3 mode, mỗi mode có centroid, diagonal variance và mixture weight; phù hợp đa mode nội class. [F §8; S slides 15–19]

Buffer/state	Shape	Giá trị/ghi chú
means μ	[19,3,256] float32	Feature center mỗi semantic mode
vars Σ_diag	[19,3,256] float32	Diagonal covariance, clamp min epsilon_sigma
weights π	[19,3] float32	Nonnegative, sum_k π[c,k]=1
occupancy / init flag	[19,3], [19,3]	Đếm sample và mode đã khởi tạo

06.2 / Source bootstrap

- Thu sampled source dense features theo source GT; map source masks xuống H/4×W/4 bằng nearest, chỉ lấy valid class pixels. Kiểm soát memory qua per-class reservoir hoặc mini-batch feature buffer.
- Chạy per-class K-means với K=3 trên feature vector D=256; tính μ từ cluster mean, Σ_diag từ per-dimension variance và π=N_ck/Σ_j N_cj; dùng floor variance và smoothing cho mode thiếu dữ liệu.
- Sau bootstrap, yêu cầu mọi class có mode hợp lệ (hoặc ghi nhận class thiếu), không có NaN, mixture weights chuẩn hóa trước khi bật Bank query trên target.

06.3 / Query và distributions

$$D_{i,c,k} = \sum_d (f_i[d]-mu[c,k,d])^2 / \max(var[c,k,d], epsSigma)$$

$$D_{i,c} = \min_k D_{i,c,k} ; d_i = \exp(-D_{i,yTeacher} / T_d)$$

$$S_i(c) = \text{logsumexp}_k(\log pi[c,k] - 0.5*D_{i,c,k})$$

$$Pproto_i(c) = \text{softmax}_c S_i(c) ; cProto_i = \text{argmax}_c Pproto_i(c)$$

Hàm query trả **(distribution_compatibility d [B,1,h,w], prototype_posterior [B,19,h,w], prototype_class [B,h,w])**. Đảm bảo shape, finite và phân phối chuẩn hóa. Query per-class-only không đủ cho REVISE: nhất thiết phải tạo all-class prototype posterior.

OPEN: GAUSSIAN SCORE Nguồn [F §8.5] dùng log-sum-exp của mixture weights và -0.5 Mahalanobis distance. Một Gaussian likelihood đầy đủ có log-determinant covariance; phiên bản đầu nên **giữ nguyên công thức nguồn** để dễ so sánh, đồng thời log variance scale và kiểm thử numerical stability.

06.4 / Bank online update + contamination control

- Tại mỗi iteration: **query bằng bank cũ trước khi update**. Source label lấy từ source GT; target label để update phải đến từ policy và đã vượt reliability gate.
- Giai đoạn đầu chỉ source features cập nhật; sau warm-up cho **ACCEPT** target tham gia; late-stage tùy ablation mới thêm very-reliable REVISE với weight nhỏ; SOFT/ABSTAIN không cập nhật.

- Với class c và mode k: hard/soft assign incoming feature theo min Mahalanobis hoặc posterior; tính weighted batch μ, variance, π; EMA m≈0.99; floor variance; Dirichlet smoothing α0; skip rare-mode batch khi sample quá ít.

```
mu[c,k]_new = m * mu_old + (1-m) * batch_mean[c,k]

var[c,k]_new = m * var_old + (1-m) * batch_var[c,k]

pi[c,k]_new = normalize_k( m*pi_old + (1-m)*pi_batch )
```

Source–target merged statistics có thể dùng λT<1 để source GT giữ vai trò anchor. Bank update hoàn toàn chạy **no_grad()** bằng detached features, không đưa means/vars/weights vào optimizer.

- Log class occupancy, số feature source/target được nhận, tỉ lệ ACCEPT update, variance min/max và tỷ lệ "invalid class/mode".

07 / Temporal Memory và evidence builders

07.1 / Temporal state

Temporal Memory theo dõi xác suất Teacher cho từng target image ID qua iterations. Để tiết kiệm RAM, nguồn khuyến nghị giữ probability memory ở H/8 hoặc H/16, FP16; xây mapping ảnh và canonical-coordinate aligned prediction. [F §9.5]

```
Memory_j(t) = gamma * Memory_j(t-1) + (1-gamma) * pTeacher_j(t), gamma≈0.9

s_i = 1 - JS( pTeacher_i(t), Memory_i(t-1) )
```

- Read previous temporal state trước update; khi image ID chưa có memory, use explicit "unavailable" flag và neutral/default fallback được log, không diễn giải non-existing memory thành high-stability evidence.
- Một target crop phải mang metadata để map đúng về canonical image (hoặc cache ở fixed canonical grid); temporal JS chỉ tính ở những location đã align và valid.

07.2 / Five evidence maps

Evidence	Công thức / nguồn	Kiểm tra
q: confidence	max_c Pteacher_i(c)	Trong [0,1], high q không có nghĩa nhãn đúng.
a: augmentation	1 − JS(Pteacher,w1, aligned Pteacher,w2)	Normalize JS để score [0,1]; identity views → a≈1.
d: distribution	exp(−D_i,teacherClass / T_d)	Lấy từ Bank; kiểm tra var floor/numerics.
s: temporal	1 − JS(Pteacher, current, memory previous)	Không dùng memory của iteration hiện tại.
b: boundary	sigmoid(EMA boundary logits)	Scalar continuous, high b ≈ boundary.

OPEN: JS NORMALIZATION Hai PDF viết 1 − JS và nói chuẩn hóa [0,1], nhưng chưa cố định log base hoặc hệ số. Chốt và unit-test một implementation JS normalized (ví dụ JS/log(2) nếu tính với log tự nhiên) cho augmentation và temporal, dùng cùng định nghĩa ở mọi phase.

08 / Multi-Evidence Trust Estimator (MTE/METE)

08.1 / Layer-by-layer canonical implementation

MTE nhận năm evidence scalars + class-conditioned embedding để ước lượng xác suất pseudo-label hiện tại đúng. Source gọi module **MTE**, slide gọi **METE**; code nên chọn một tên, ví dụ MultiEvidenceTrustEstimator. [F §9; S slides 20–23]

Layer	Tensor	Chú thích
Evidence concat q,a,d,s,b	[B,5,h,w]	Đã align cùng coordinates và resolution
Embedding(labelTeacher, 19×16)	[B,16,h,w]	Gather theo raw predicted class, never GT on target
Concat	[B,21,h,w]	21 = 5 evidence + 16 class features
Conv1×1, 21→64 + GELU	[B,64,h,w]	Pointwise nonlinear fusion
Dropout(p=0.1)	[B,64,h,w]	Regularization
Conv1×1, 64→32 + GELU	[B,32,h,w]	Pointwise
Conv1×1, 32→1 + sigmoid	[B,1,h,w]	Reliability r_i

- Phải kiểm tra gradient chỉ update MTE qua correctness-calibration loss; target reliability dùng trong policy nên detach để tránh circular pseudo-supervision gradient.

OPEN: 21 versus 25 channels Tại [F §9.8, Appendix A], cấu hình nhất quán là **21→64→32→1**. Tuy nhiên [F §19 và bảng I/O §18] còn nhắc cấu hình 25 chiều hoặc spatial role embedding. **Quyết định tham chiếu:** dùng 21-D continuous b cho V1/full đầu tiên; 25-D chỉ là extension phải có tensor contract riêng và ablation.

08.2 / Huấn luyện correctness calibration trên source

Không có target correctness GT, vì vậy MTE được train trên **corrupted source** với blur/noise/fog/color/brightness perturbations. Teacher/student dự đoán trên corrupted source; correctness GT g_i=1[prediction_i=source_label_i]. MTE học nhờ weighted BCE. [F §9.9–9.12; S slide 23]

```
g_i = 1[ yPred_corruptedSource_i == yGT_source_i ]

Ltrust = -mean_valid( w1*g_i*log(r_i) + w0*(1-g_i)*log(1-r_i) )
```

- Invalid/ignore pixels phải masked; số correct/incorrect thường mất cân bằng nên dùng balanced sampling hoặc class-balanced BCE. Split calibration train/validation và theo dõi AUROC/AUPRC, ECE, Brier score.
- Source evidence d cần dùng source-initialized Bank; temporal s nếu không có real history phải có thủ tục tạo history từ các phiên dự đoán nhất quán, không được giả lập “stability” mà không ghi nhận cơ chế.
- Tại target branch không tính correctness BCE vì không có GT; chỉ forward MTE để lấy reliability. Không fine-tune MTE bằng chính pseudo-label mục tiêu khi chưa có protocol riêng.

09 / Four-State Pseudo-Label Policy (FSPD)

Policy là rule-based, không có trainable parameters. Input: pT, teacher hard label, r, Pproto, prototype top class/margin, class-specific thresholds từ BPCC; output: hard labels, soft probabilities, masks và weights. [F §10; S slides 24–29]

State	Trigger logic	Outputs / loss
ACCEPT	r ≥ tau_high[c] và không có prototype conflict mạnh	Yhard=yTeacher; weight=1; M_A=1; Lhard
REVISE	protoTop != yTeacher, protoTopProb > eta, top1-top2 > delta, r < tau_very_high; safeguard applies	Yhard=protoTop; weight w_R<1; M_R=1; Lhard
SOFT	tau_low[c] < r < tau_high[c], không đủ điều kiện REVISE	Psoft=alpha*pT+(1-alpha)*Pproto; M_S=1; Lsoft
ABSTAIN	r ≤ tau_low[c] hoặc conflict rất mạnh/unsafe	M_X=1; không hard/soft label loss trong iteration

Psoft_i = alpha_i * Pteacher_i + (1-alpha_i) * Pproto_i; sum_c Psoft_i[c] = 1

M_A + M_R + M_S + M_X = 1; Mhard = M_A + M_R; Msoft = M_S

09.1 / Deterministic order & no-overlap implementation

```
def route(r, teacher_cls, pT, pProto, tau_hi, tau_lo, cfg):
    # 1. Calculate proto top1/top2, margin, conflict.
    # 2. REVISE if strong alternate + teacher not very-high trust.
    # 3. ACCEPT if high trust and no strong conflict.
    # 4. SOFT if (tau_low < r < tau_high) and not rejected.
    # 5. Remaining pixels: ABSTAIN.
    # Return labels, soft_probs, MA, MR, MS, MX, weights.
    # Keep masks mutually exclusive with one assigned state per pixel.
```

- Trước khi routing, tìm top2 prototype classes, margin; xác định safeguard tránh trust quá cao bị sửa vô cớ và tránh prototype Bank bất ổn.
- Khi confidence cao nhưng conflict quá mạnh, nếu chưa chứng minh sửa nhãn có precision tốt, ưu tiên ABSTAIN trong policy conservative; cần ghi rõ ngưỡng/protocol trong config.
- Nếu không có valid pseudo-label ở state nào, loss tương ứng trả zero tensor trên đúng device/dtype và không chia cho zero.

OPEN: POLICY MISSING THRESHOLDS Nguồn cho rule và thứ tự REVISE→ACCEPT→SOFT→ABSTAIN nhưng **không cố định các giá trị** eta, delta, tau_very_high, conflict threshold và w_R. Những ngưỡng này cần cấu hình riêng và source-corruption validation; mọi ablation phải lưu lại values.

10 / Balanced Progressive Coverage Curriculum (BPCC)

BPCC là thống kê/controller ngoài gradient điều khiển threshold theo class và training progress; không phải neural network và không học bằng optimizer. [F §11; S slides 30–32]

State/controller	Nội dung lưu	Đầu ra
Class counts	N_pred[c], N_used[c] + state counts	Coverage κ[c]
Reliability EMA	running mean rbar[c], βr	Stability guard
Target schedule	κmin[c], κmax[c], g(t/T)	Desired coverage κ*(c,t)
Threshold controller	eta, lambda, r_min, min/max tau	tau_high[c], tau_low[c]

```
coverage[c] = Nhard_used[c] / max(Nteacher_pred[c], eps)
desired[c,t] = kappaMin[c] + (kappaMax[c]-kappaMin[c])*g(t/T)
tauHigh[c,t+1] = clip(tauHigh[c,t] + eta*(coverage-desired) + lambda*max(0,rMin-rbar[c]))
tauLow[c,t] = tauHigh[c,t] - deltaTau
```

Thay thế được nguồn đề xuất: chọn tauHigh bằng quantile của reliability theo class, kèm safety floor. Controller nên cập nhật theo epoch/running window, không bắt buộc mỗi minibatch; không cho rare-class threshold dao động dữ dội vì sample ít.

- Log theo class: threshold, count từng state, coverage, mean reliability, target bank occupancy. Không dùng Cityscapes GT để điều chỉnh controller trong UDA training.

11 / Objective function: tám losses và bố trí rõ ràng

Theo [F §13], full objective gồm 8 losses (source segmentation, source boundary, target hard, target soft, target boundary, target consistency, target prototype, source trust calibration). Không cần bật toàn bộ từ epoch đầu. Loss được tổ chức theo **branch, state mask và gradient route**.

```
Ltotal = Lsup + lambda_sb*LbndS + lambda_h*Lhard + lambda_s*Lsoft
+ lambda_tb*LbndT + lambda_c*Lcons + lambda_p*Lproto + lambda_r*Ltrust
```

Loss	Input và mask	Formula / gradient nhận
Lsup	Student source logits; GT source valid	CE(zS(xs), ys) → Student encoder+seg head
LbndS	Student source boundary; source boundary GT	BCE + λD Dice → Student features + Boundary Head
Lhard	Student target strong logits; MA/MR hard labels	Masked weighted CE; ACCEPT w=1, REVISE wR<1 → Student
Lsoft	Student strong probs; Psoft; MS	Masked weighted KL(Psoft || pStudent) → Student
LbndT	Boundary strong output; reliable target edge mask	Masked BCE + λD Dice → Student + Boundary Head
Lcons	Aligned teacher weak probs; student strong; reliability	Masked/reliability-weighted KL(pT || pS) → Student
Lproto	Student strong Fdense; Bank center/variance; hard labels	Mean min-mode Mahalanobis distance → Student Fdense only
Ltrust	MTE output on corrupted source; source correctness GT	Weighted BCE → Trust Estimator only (via detached evidences)

11.1 / Hard target loss: ACCEPT + REVISE

Lhard = - sum_i[Mhard_i * w_i * log pStudent(i,Yhard_i)] / (sum_i Mhard_i*w_i + eps)

Đặt w=1 tại ACCEPT và w=wR<1 tại REVISE; chỉ pixel sau geometric warp với valid hard label mới đóng góp. Dùng logits CE per pixel (reduction=none) rồi apply masks/weights. Nếu denominator=0, trả loss=0.

11.2 / Soft target loss: SOFT only

Lsoft = sum_i[MS_i * wS_i * KL(Psoft_i || pStudent_i)] / (sum_i MS_i*wS_i + eps)

Psoft không được argmax trước KL. Cần clamp+renormalize distribution; detach target probs; masked KL theo channel/class. Không bao gồm ABSTAIN.

11.3 / Consistency loss

Lcons = sum_i[Wcons_i * KL(warp(pTeacher_i) || pStudent_i)] / (sum_i Wcons_i + eps)

Nguồn dùng reliability r_i làm weight; có thể additionally mask ABSTAIN để conservative. Warp teacher distribution về strong-view coordinates trước khi tính; không backprop vào Teacher.

11.4 / Boundary losses

LbndS = BCE(bSource, boundaryGT(ys)) + lambdaDice * DiceLoss(bSource, boundaryGT)

LbndT = maskedBCE(bTarget, refinedSemanticEdge) + lambdaDice * maskedDice(...)

Target semantic edge đến từ refined hard labels, được chọn khi Teacher boundary probability cũng vượt ngưỡng; invalid/dilated boundaries phải tránh tràn vào ignored regions.

11.5 / Prototype + calibration losses

Lproto = mean_i[min_k Mahalanobis(Fstudent_i, Q[Yhard_i,k])], valid reliable hard mask

Ltrust = WBCE(MTE(sourceEvidence), correctnessFromSourceGT)

- Lproto: gradient chạy qua Student feature; Bank statistics detached; không cập nhật Bank qua loss này. Ltrust: source correctness label và source evidence được tính từ upstream predictions dưới no-grad, ngăn gradient ngoài ý muốn qua calibration labels.

11.6 / Activation matrix theo ba milestone

Loss	Source-only	EMA Baseline	CRISP-DA V1	Full CRISP-DA
Lsup	ON	ON	ON	ON
Lhard	OFF	ON: Keep	ON: A+R	ON: A+R
Lsoft	OFF	OFF	ON	ON
Lcons	OFF	OFF (base)	ON	ON
Lproto	OFF	OFF	ON	ON
Ltrust	OFF	OFF	ON	ON
LbndS	OFF	OFF	OFF	ON
LbndT	OFF	OFF	OFF	ON

V1 = source-described reduced system: Bank + MTE(q,a,d,s) + Four-State Policy, tạm bỏ Boundary/BPCC [F §26]. Bảng trên là cấu hình đối chứng được đề xuất, không bắt buộc bật mọi loss V1 ở bước đầu tiên.

LOSS-LEVEL CONTRACT Chỉ được tính loss tại locations thuộc state tương ứng; normalize bằng tổng valid weight, không cố định H×W; clamp log probs; teacher targets, prototype posterior, confidence/r và ref labels phải detached. Các λ đều là hyperparameters cần tune, nguồn không cho bộ giá trị final.

12 / Training pipeline: chi tiết một iteration

Implementation phải giữ thứ tự **read old state → determine targets → optimizer → update non-gradient state**, để tránh self-leakage. Đây là chu trình chuẩn [F §14.5–14.8, §15].

Bước	Action	Expected output / invariant
01	Load paired source batch (xs,ys) + unlabeled target batch xt, image IDs, transform metadata	source GT valid, target no GT
02	Forward source through Student; compute Lsup and LbndS if enabled	zS, Fsource, bS
03	Create two target weak views; EMA Teacher no_grad forward; align predictions	pT1, pT2, FT, yRaw
04	Query CURRENT Bank (before update); read previous temporal memory	d, Pproto, s
05	Compute evidence q,a,d,s,b; forward MTE to get r	B×1×h×w, finite
06	Read BPCC thresholds; route Four-State Policy	Yhard, Psoft, MA/MR/MS/MX; masks sum=1
07	Build strong target view; warp targets/masks/weights; Student target forward	student logits and dense features aligned

Bước	Action	Expected output / invariant
08	Compute applicable target losses and source trust calibration loss	per-loss finite with safe masked means
09	Aggregate weighted Ltotal; backprop; optimizer step, scheduler update	trainable weights updated
10	EMA Teacher update from new Student params	teacher requires_grad=False
11	Update Bank via source + reliability-gated target detached features	No Bank gradient / no current-sample leakage
12	Update temporal memory; class counts; append logs	State ready for next iteration
13	End epoch/window: BPCC threshold update; evaluate / checkpoint	clear global_step and phase state

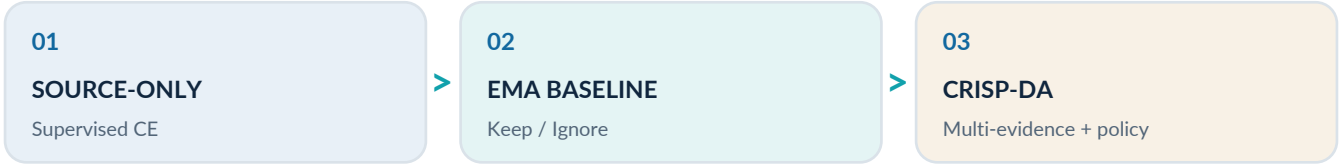
Training use **two-level curriculum**: outer experimental milestones (Source-only/Baseline/CRISP-DA); internal full CRISP-DA schedule (preprocessing → source bootstrap → conservative adaptation → full adaptation). [F §14; S slides 36–37]

12.1 / Internal full CRISP-DA curriculum

Pha nội bộ	Hoạt động / điều kiện
Stage 0 — Preprocess	Label mapping, crop size, boundary GT, two weak + strong augmentation, image identity/temporal cache.
Stage 1 — Source bootstrap (≈15–25%)	Train Student Lsup, Boundary Head LbndS; collect source Fdense; Bank source bootstrap; corrupted-source trust calibration; initialize Teacher.
Stage 2 — Conservative adaptation (≈15–25%)	Threshold cao; ACCEPT/ABSTAIN primary, REVISE optional strict; giữ source anchor; only ACCEPT target for bank updates.
Stage 3 — Full adaptation (remaining budget)	All four states; soft/consistency/proto/target boundary; BPCC; update source + ACCEPT and optional high-precision REVISE to Bank.

OPEN: SLIDES / FULL DIFFERENCE S slide 36 mô tả conservative adaptation chỉ tính source objective, nhưng F §14.3 đã cho phép target hard supervision thận trọng. **Plan triển khai:** để benchmark rõ, quy định warm-up source-only rồi bật target ACCEPT loss theo flag riêng; ghi rõ experiment ID.

13 / Implementation roadmap: ba mốc độc lập



13.1 / Milestone A — Source-only (supervised reference)

Mục tiêu: đảm bảo dataset mapping, MiT-B5, decoder, objective CE, optimizer, checkpoint, validation đều hoạt động. Không sử dụng Cityscapes train images trong optimization. Đây là negative/control experiment để đo domain gap.

Work package	Tác vụ code cụ thể	Done / evidence
A1 Dataset	GTA5 loader image+trainIds; Cityscapes val loader; class palette; ignore=255; sample visualization	Overlay 30 images/masks; class histogram; no label mismatch
A2 Model	Pretrained MiT-B5; projector; seg head; output shape contract	forward/backward unit tests; logits finite
A3 Optimization	CE ignore_index; AdamW; LR groups; scheduler; mixed precision; gradient clip optional	Loss finite, training steps move, GPU memory log
A4 Evaluation	Confusion matrix 19×19; per-class IoU; mIoU; optional visual predictions	Evaluation reproducible from checkpoint
A5 Recovery	Latest/best weights + optimizer/scaler/scheduler/step/RNG/config	Resume succeeds with same settings

```
L_A = CE( Student(xs), ys )
```

EXIT GATE A Run finite loss on multiple batches, observe learning signal, save and reload checkpoint, compute correct Cityscapes-val mIoU without target GT leakage. Không có mIoU threshold cứng nào được hai PDF yêu cầu.

13.2 / Milestone B — EMA self-training baseline

Mục tiêu: tạo benchmark "global confidence Keep/Ignore" nêu ở [F §22, §27]. Baseline phải xuất phát từ source-only checkpoint và **không** tích hợp Bank/MTE/Four-State/BPCC để phép so sánh sáng rõ.

Work package	Tác vụ code cụ thể	Done / evidence
B1 EMA Teacher	Deep copy Student at initialization; freeze gradients; update α after optimizer	Teacher diverges smoothly; zero gradients
B2 Weak/strong views	Target weak to Teacher and strong to Student; align all masks	Flip/warp tests; same spatial support
B3 Pseudo-labeling	pTeacher softmax; yRaw argmax; q max; fixed global tau; Keep/Ignore mask	coverage, confidence histogram and label map
B4 Target objective	Masked hard CE on Keep pixels; ignore others; combined Lsup + λt Ltarget	Zero-kept-pixel batch stable; target loss finite
B5 Experiment control	Tune tau and λt via defined protocol, freeze seeds/compute/budget	Source-only vs EMA baseline table; checkpoints

```
mask_i = 1[max_c PTeacher_i(c) >= tau]
L_B = Lsup + lambda_t * weightedMaskedCE(Student(strong(xt)), yRaw, mask)
```

- Ghi theo iteration: selected-pixel coverage toàn cục và theo class, target CE, teacher vs student disagreement, visual predictions, mIoU. Lưu source-only và baseline vào hai run directories độc lập.

EXIT GATE B Chạy từ đầu tới cuối một training budget xác định, có thể resume sau Molab shutdown; teacher update chính xác; target pseudo-label branch có effect thực sự; mIoU/per-class metrics và coverage đầy đủ. Không khẳng định cải thiện nếu kết quả chưa được đo.

13.3 / Milestone C — CRISP-DA: incremental feature rollout

Mục tiêu: thay Keep/Ignore bằng reliability-aware supervision và thí nghiệm xem modules đóng góp gì. Nên triển khai reduced V1 trước, sau đó mới bật Full CRISP-DA. [F §22, §26–27]

Subphase	Thứ tự phụ thuộc / module	Artifact and gate
C0	Freeze Baseline and metrics; expose Fdense [B,256,h,w], valid coordinate metadata	Common training interface, no regression
C1	Source Bank bootstrap K-means; 19×3×256 means/vars; logsumexp Pproto	Bank queries finite, mode occupancy non-zero
C2	Two weak-view augmentation consistency (a) + temporal memory (s)	Identity JS and temporal alignment tests pass
C3	MTE reduced V1 with q,a,d,s + class embed; source corruption calibration	Correctness AUROC/ECE measured on held-out source
C4	Four-State Policy: A/R/S/X, masked CE and KL; Bank gated update	Masks exclusive, REVISE guard and soft-normalization tests
C5	Prototype loss + reliability-weighted consistency; early target learning	No NaN, gradient route correct, mIoU and coverage measured
C6	Boundary Head + b evidence; source and target boundary losses	Boundary-IoU and boundary evidence ablation
C7	BPCC with per-class dynamic thresholds and safeguards	Tail coverage trend and precision-coverage diagnostics

- C1–C5 = reduced CRISP-DA V1 theo [F §26]. C6–C7 mới là full extension. Phải giữ clear experiment IDs và configs để tránh “module stacking” không đánh giá được từng đóng góp.

EXIT GATE C V1 và Full chạy được bằng config riêng; results mIoU/per-class IoU/boundary/precision–coverage/calibration; paired comparisons với Source-only và EMA Baseline; ablation table hợp lệ với cùng dữ liệu, crop và compute budget.

14 / Repo modules, code ownership, phụ thuộc

```
crisp_da/
  configs/{source_only,ema_baseline,crisp_v1,crisp_full}.yaml
  data/{gta5.py,cityscapes.py,remap.py,transforms.py,cache.py}
  models/{mit_b5.py,dense_decoder.py,seg_head.py,boundary_head.py}
  adaptation/{ema.py,prototype_bank.py,temporal_memory.py}
  adaptation/{evidence.py,trust_estimator.py,four_state.py,bpcc.py}
  losses/{source.py,hard_soft.py,boundary.py,consistency.py}
  losses/{prototype.py,trust.py,total_objective.py}
  engine/{trainer.py,phase_schedule.py,checkpoint.py,evaluator.py}
  tests/{test_shapes.py,test_ema.py,test_policy.py,test_bank.py}
  scripts/{train_source.py,train_baseline.py,train_crisp.py}
  README.md  requirements.txt  experiment_manifest.yaml
```

Interface	Signature / contract
Student	forward(x)-> {logits, Fdense, features}; logits always [B,19,H,W]
Teacher	predict(weak1,weak2)-> probs, features, yRaw, warp_meta
Bank	bootstrap(sourceFeatures,GT); query(features,teacherCls)-> d, Pproto; update(detachedSamples,policyMasks)
Evidence	build(q,a,d,s,b,teacherCls,meta)-> aligned [B,E,h,w]
MTE	forward(evidences,teacherCls)-> r; source_calibrate(...)-> Ltrust
Policy	route(r,pT,Pproto,tauHi,tauLo)-> Yhard,Psoft,masks,weights
BPCC	observe(class,states,r); update(window)-> tauHi,tauLo
Loss aggregator	compute(sourceBatch,targetBatch,outputs,phaseFlags)-> loss dict + total

14.1 / Suggested config keys

```
experiment:
  stage: source_only | ema_baseline | crisp_v1 | crisp_full
  seed: 42  # implementation choice, not validated hyperparameter
model:
  name: mit_b5
  num_classes: 19
  dense_dim: 256
train:
  amp: true
  batch_size: <adapt_to_gpu_memory>
  crop_size: <choose_and_record>
  lr_backbone: 6.0e-5
  lr_heads: 6.0e-4
  weight_decay: 0.01
ema:
  momentum: 0.999
pseudo:
  global_threshold: <sweep_for_baseline>
bank:
  num_modes: 3
  momentum: 0.99
trust:
  class_embedding_dim: 16
  evidence_channels: 5 # full; 4 for reduced V1
  hidden_channels: [64, 32]
  dropout: 0.1
objective:
  coefficients: <explicit_per_phase_dict>
```

Các giá trị LR/EMA/K/D/dropout là điểm bắt đầu từ [F §19]; seed, batch size, crop, threshold và lambda loss là quyết định code/experimental tuning. Không điền số tùy tiện vào kết quả khoa học.

15 / Molab, dataset và training reproducibility

Workflow tham chiếu: code phát triển trên VS Code/local, source versioned trong Git repository; GTA5/Cityscapes lưu riêng dưới hình thức dataset archives hoặc pre-sharded object storage; Molab tải/cache theo nhu cầu; checkpoint/logs đồng bộ về durable cloud storage. Đây là đề xuất môi trường triển khai, không phải đặc tả bắt buộc của hai PDF.

Thành phần	Yêu cầu
Dataset paths	Remote URIs chỉ chứa trong environment/config; dataset GT target train không mở vào trainer
Archive strategy	ZIP có thể lưu cloud; trong Molab chỉ giải nén subset hoặc cache shards trong runtime disk
Preflight	Verify free disk, split lists, archive checksum, image/label existence, 19 train IDs
Compute safety	Mixed precision, configurable batch/crop/grad accumulation; runtime resource monitoring
Checkpoint	Save Student, Teacher, Boundary/MTE when used, optimizer/scheduler/scaler, epoch, step, seeds, Bank, BPCC and memory policy
Persistent storage	Upload checkpoints/logs periodically and on stage transitions; verify reload before long run

OPEN: TÀI NGUYÊN MOLAB Hai PDF không chỉ định VRAM, batch/crop tối ưu, molab persistent disk hay dataset size. Hãy đo thực tế trên session GPU và giảm crop/batch nếu OOM; checkpoint/resume là bắt buộc trước khi chạy benchmark dài.

16 / Evaluation, ablation và reporting protocol

16.1 / Main metrics

Nhóm	Metrics cần báo
Segmentation	mIoU; per-class IoU; confusion matrix; Cityscapes val qualitative overlays
Balance / boundary	Head-vs-tail IoU; Boundary-IoU hoặc trimap IoU
Pseudo-label quality	Precision, recall, coverage (chỉ tính khi có proxy/diagnostic GT hợp lệ); precision–coverage curve
Trust calibration	AUROC/AUPRC error detection, ECE, NLL hoặc Brier, reliability diagram
Revision/policy	REVISE correction precision, counts A/R/S/X per class, abstention utility
Efficiency	Train GPU hours, peak memory, samples/s, inference latency vs Student-only

Vì target train không có nhãn, pseudo-label correctness/precision trên đó không thể quan sát trực tiếp theo UDASS; hãy dùng held-out labeled evaluation riêng hoặc corrupted-source proxy, tách khỏi training và nói rõ nguồn metric. [F §23–24]

16.2 / Ablation ladder theo nguồn

Exp	Mô hình	Câu hỏi đo lường
E0	Source-only SegFormer	Domain gap trước adaptation
E1	EMA self-training + fixed global threshold	Baseline pseudo-label quality
E2	+ class-conditioned trust estimator (confidence only)	Trust calibration vs max softmax
E3	+ augmentation evidence a	Perturbation stability có ích?
E4	+ temporal stability s	History có cải thiện calibration?
E5	+ multi-prototype distribution evidence d	Bank, prototype posterior có ích?
E6	+ Four-State Policy	Keep/Ignore vs A/R/S/X
E7	+ Boundary Head/evidence/loss	Boundary pixels / thin structures
E8	+ BPCC	Tail class coverage trade-off

- Giữ cùng data split, encoder/checkpoint initialization, image scale/crop, total optimizer steps, val protocol và seeds khi so sánh; lưu config exact của mỗi run.

- Additional ablations: single vs multi-prototype; confidence-only vs multi-evidence; four-state vs Keep/Ignore; BPCC controller vs quantile schedule; Bank target ACCEPT-only vs adding REVISE.

17 / Unit/integration tests và pass/fail gates

Test	Assertion cụ thể
Tensor/geometry	All evidence B×1×h×w same aligned frame; warp identity and double flip correct.
Source labels	Every valid ID [0..18]; ignore=255; source image/label sizes match.
Teacher freeze	requires_grad=False; all Teacher grads None; EMA numerical difference matches formula.
Bank variance	μ, var, π finite; var ≥ variance_floor; ∑_kπ[c,k]≈1; Bank excluded optimizer.
Prototype query	feature==μ of mode gives small D, high compatibility; posterior ∑_cP≈1.
JS evidence	Identity augmentation a≈1; previous temporal state used, not current.
Policy masks	MA+MR+MS+MX == 1; no overlap; confidence ramp hits states correctly.
REVISE safeguard	Tiny top1-top2 prototype margin never revises; extremely high-trust Teacher protected.
Soft target	Psoft sums to 1; no accidental argmax; masked KL finite.
Zero-mask loss	No ACCEPT/REVISE/SOFT batch yields zero, never NaN/inf.
Gradient routing	Student receives source/target gradients; MTE receives only Ltrust; Bank/Teacher no gradients.
Leakage	Bank query before same-step Bank update; eval GT never passed into adaptation.
Resume	Reload preserves optimizer/scaler, EMA, Bank, BPCC, step and required memory state.

18 / Unresolved decisions: implementation sign-off list

Đầu mục cần chốt	Tình trạng / khuyến nghị
SegFormer exact implementation	Không đủ internals trong PDF; khóa library version, pretrained weights, head configuration.
MTE input 21 vs 25	Chọn 21-D canonical, 25-D role embedding như ablation extension.
JS normalization	Chọn thống nhất definition and denominator; test identity/symmetry.
Global tau Baseline	Sweep trên protocol cố định; không tuyên bố 0.95 là optimum.
Policy thresholds eta/delta/veryHigh	Có quy tắc trong source nhưng thiếu numeric defaults; tune source proxy.
Bank sample assignment/floor	Min-Mahalanobis, sample floor và smoothing cần config; no hardcoded magic.
MTE temporal evidence in corrupted-source	Chỉ rõ how history is built; missing history must be explicit.
Stage 2 conservative training	Chọn explicit target-hard flag vì slide vs full text diễn đạt khác nhau.
BPCC update cadence	Update per epoch/window, source allows; slides mention each iteration.
Compute budget / storage	Molab exact resource allocation chưa có trong PDF; đo trong runtime.

RESEARCH INTEGRITY Các phần MTE/Bank/Policy/BPCC là proposal cần ablation. Tài liệu này không khẳng định CRISP-DA đã vượt baseline hay có “best hyperparameters”. Những quyết định thêm để triển khai được gắn [DECISION]/[OPEN], tránh trộn kiến thức bên ngoài với nguồn gốc.

19 / Definition of Done — bàn giao cho người code

- **Milestone A:** source-only full training + validation; correct 19-label mapping, inference overlay, save/resume; fixed pretrained checkpoint.
- **Milestone B:** EMA self-training global-threshold, target pseudo-label mask, weak/strong aligned views, source/target losses; repeatable mIoU and coverage report.
- **Milestone C V1:** Bank initialized/updated, MTE calibrated, Four-State masks, hard/soft/prototype/consistency training, correctness and gradient invariants.
- **Milestone C Full:** Boundary Head and losses, BPCC, temporal memory, all 8 objective components, ablations and efficiency report.
- **Release artifacts:** source code + exact configs, environment lock, dataset split manifests, validation outputs, model states/checkpoints, metrics tables, unit/integration test log, runbook for Molab restart.

20 / Tài liệu tham chiếu và traceability

Source	Các mục then chốt đã sử dụng
[F] CRISP_DA_full(1).pdf	§4 computational graph; §5–7 backbone, EMA, Boundary; §8 Bank; §9 MTE; §10 Four-State; §11 BPCC; §12–13 training/loss; §14–15 iteration; §16–19 tests/config; §20–27 inference/ablations/milestones; Appendix A.
[S] CRISP-DA_Part1(1).pdf	Slides 4–8 motivation; 10–14 architecture + boundary; 15–19 Bank; 20–23 METE; 24–32 routing/curriculum; 33–35 objectives; 36–37 training stages.

Phạm vi của bản implementation plan: mô tả đầy đủ những layer/structures được nguồn quy định; nơi nguồn không nêu exact micro-architecture và hyperparameter numeric thì để open/implementation choice, không tự nhận là “theo tài liệu gốc”. Bản này là **coding blueprint, không phải source-code implementation**.